



Aula 1b: A pipeline do ML

Aprendizado de Máquina (APMAI) - IASEG


O fluxo geral




Problema



Pergunta




Aprendizado
de máquina



Resposta/
Solução

O fluxo geral




Mas o que acontece aqui dentro?


O pipeline do aprendizado de máquina

As etapas comuns à qualquer aplicação


As sete etapas



Após a avaliação, recomeçamos o processo



E quando o modelo é aprovado



(Visualização atravessa todas as etapas!)

Agora vamos ver na prática com o dataset *Iris*

iris setosa



petal

sepal

iris versicolor



petal

sepal


iris virginica



petal


sepal

O modelo que usamos: kNN (k-nearest neighbours)



O modelo que usamos: KNN (k-nearest neighbours)

Largura da pétala (cm)



species

● setosa

■ versicolor


◆ virginica

○ Novo dado
(x=2.2, y=0.9)

Comprimento da pétala (cm)

O modelo que usamos: KNN (k-nearest neighbours)

Largura da pétala (cm)





species

- setosa
- versicolor
- ◆ virginica


○ Novo dado
(x=2.2, y=0.9)

Comprimento da pétala (cm)


O que significa o “k”?



O kNN não “aprende”; ele verifica



O classificador kNN
precisa olhar os dados
para prever



Uma árvore de decisão (como
no exemplo do banco) existe
separada dos dados

O projeto da nossa disciplina

Como faremos a avaliação

Descrição do projeto

- **Objetivo:** construir um modelo preditivo sobre um conjunto de dados escolhido pelo grupo e documentar tanto o processo quanto o resultado.


Vocês vão precisar...



Se reunir em grupos de 4
pessoas



Escolher um conjunto de
dados para usar



Treinar um modelo de
aprendizado de máquina



Entregar um notebook +
relatório do modelo

A apresentação e as perguntas

Cerca de **15 minutos por grupo**: uns 5 minutos apresentando o trabalho, uns 10 minutos de perguntas.

- As perguntas são dirigidas a pessoas específicas, não ao grupo.
 - **O banco de perguntas será publicado em 24/09.** Vocês vão saber de antemão o que pode ser perguntado — não para facilitar, mas para que todos estejam preparados para todas elas.
 - As perguntas são sobre o projeto de vocês, não sobre teoria solta.
-

O que está sendo avaliado

- Um modelo que não funciona bem é um resultado perfeitamente aceitável neste projeto, desde que vocês saibam dizer por quê.
- **O que não está sendo avaliado é quão bom o modelo é, mas o entendimento de vocês dos conceitos e do processo por trás do aprendizado de máquina.**


Prazos

Quando	O quê
22/09 , monitoria	Formação dos grupos e escolha do conjunto de dados
24/09 , monitoria	Último dia para trocar de conjunto de dados · aprovação de dados fora da lista · publicação do banco de perguntas · cada integrante declara por quais seções do relatório responde
02/10 , 23h59	Entrega (<i>data a confirmar</i>)
05/10 , manhã	Apresentação e perguntas (<i>data a confirmar</i>)

As duas últimas datas dependem de um ajuste no cronograma que ainda está sendo confirmado. Se mudarem, avisaremos com antecedência.

A pergunta e o problema


Dado o perfil desse cliente, deveríamos aprovar seu empréstimo?



Isso é um problema de classificação!


Outra opção de pergunta e problema

Quais perfis de risco existem na nossa base de clientes?



Isso é um problema de agrupamento!

1 problema, várias perguntas, várias soluções possíveis



Amanhã: aula de manhã, monitoria à tarde

Quando	O quê
22/09, 09h–13h	Aula 2: Entendendo um conjunto de dados
22/09, 14h–17h	Monitoria com o Lucas: definição de grupos e datasets
No Moodle	O notebook de hoje e a descrição completa do projeto