



Aula 3: Avaliando modelos

Aprendizado de Máquina (APMAI) - IASEG

As sete etapas do aprendizado de máquina



As sete etapas do aprendizado de máquina



- Quais problemas podem ser resolvidos com aprendizado de máquina?
- Quais técnicas posso usar?
- **Como sei que meu modelo está bom?**
- Por que um modelo que acerta ainda pode falhar?
- Dá para fazer melhor, e o que custa?
- O que eu posso afirmar sobre o meu modelo após treiná-lo?

A base de hoje

O que é	Bank Marketing (UCI)
Fonte dos dados	Dados de telemarketing de um banco português
Cada linha representa	Uma pessoa para quem o banco ligou oferecendo um investimento
Tamanho	41.188 linhas × 21 colunas
Coluna-alvo	Registra se a pessoa aceitou ou não o investimento


O modelo que queremos aprender

Classe

Variable Name	Role	Type	Demographic	Description
age	Feature	Integer	Age	
job	Feature	Categorical	Occupation	type of job (categorical: 'admin.','blue-collar','entrepreneur','housemaid','employed','services','student','technician','unemployed','unknown')
marital	Feature	Categorical	Marital Status	marital status (categorical: 'divorced','married','single','unknown'; note: 'unknown' includes widowed)
education	Feature	Categorical	Education Level	(categorical: 'basic.4y','basic.6y','basic.9y','high.school','illiterate','professional.course')
default	Feature	Binary		has credit in default?
balance	Feature	Integer		average yearly balance
housing	Feature	Binary		has housing loan?
loan	Feature	Binary		has personal loan?
contact	Feature	Categorical		contact communication type (categorical: 'cellular','telephone')
day_of_week	Feature	Date		last contact day of the week

Features

Mas como modelar essa relação?




Podemos considerar que a saída do modelo para uma nova observação seria a média dos k vizinhos mais próximos.

$$y = \frac{8 + 8 + 10 + 6 + 12}{5} = \frac{44}{5} = 8,8$$


(Continua sofrendo os problemas que vimos que o kNN tem: depende do valor de k , precisa olhar todos os dados sempre, etc.)

Exemplo: regressão do salário com base nos anos de empresa






Algumas linhas (modelos) possíveis

$$y=8.000$$







$$y=2000 + 2000 \times \text{anos}$$



$$y=8000+1000 \times \text{anos}$$

$$y=2000+1000 \times \text{anos}$$

A avaliação de cada um desses modelos




As equações do slide anterior descrevem os modelos

$$\text{salário} = 2.000 + 1.000 \times \text{anos}$$

os dois números em amarelo são os **parâmetros**


Treinar um modelo = achar os parâmetros

De uma coluna para muitas




um peso por coluna → soma o resultado dos produtos dos pesos e dos valores das features → gera uma saída numérica

A regressão linear “aprende” os parâmetros



O kNN precisa olhar os dados para prever



Após aprender um modelo via regressão linear, **não precisamos mais olhar os dados** para fazer uma previsão

Todo modelo é uma aproximação de algum oráculo




Ideal teórico:

Sabe a resposta correta
sempre



Realidade prática:

Dados



O que podemos treinar:

Modelo

Terminando a regressão

(Voltamos para o notebook)

Como o modelo deveria usar uma coluna de texto?

job
retired
student
admin.



admin.	retired	student	... +9
0	1	0	0
0	0	1	0
1	0	0	0

1 coluna de texto com 12 valores → **12 colunas de 0 ou 1**

O modelo de regressão linear faz uma soma



aposentado(a)
casado(a)
ensino médio
sem inadimplência
com financiamento de casa
sem empréstimo pessoal


Ponto de partida	47,5 anos
aposentado	+19,0
casado	-2,3
ensino médio	-5,4
financiamento de casa	+0,1
$47,5 + 19,0 - 2,3 - 5,4 + 0,1 = \mathbf{58,9 \text{ anos}}$	

As outras 22 colunas estão desligadas: $0 \times \text{peso} = 0$.


O modelo inteiro são **27 números** (26 pesos + 1 ponto de partida).
Por isso dá para apagar as 41.188 linhas.

Valores iguais das features = mesma saída do modelo

Doze pessoas dos dados de teste tem exatamente o perfil do slide anterior.



O modelo gera $y = 58,9$ para todas!



O erro não é falta de dados: essas seis colunas **não são o bastante para calcular** a idade de ninguém de forma adequada. Mais dados não resolveriam o problema.

Quanto o modelo erra?

idade real	idade prevista	erro
57	39,3	17,7
55	50,5	4,5
33	38,4	5,4
36	39,7	3,7
27	42,3	15,3

Erro médio: em média, **quão longe** a previsão fica da resposta real.

(em inglês: *mean absolute error*, MAE)



Duas medidas de erro diferentes:

Treino: 6,6 anos
para escolher a reta



Teste: 6,5 anos
para julgar a reta

$$\text{erro médio} = \frac{|57 - 39,3| + |55 - 50,5| + |33 - 38,4| + \cdots}{8.238 \text{ pessoas do teste}} = \mathbf{6,5 \text{ anos}}$$

Como podemos avaliar se o modelo que treinamos é bom?




Essa linha não aprende nada (é só o valor da média dos dados), e ainda erra menos que duas retas inclinadas.




Sempre devemos ter um modelo de referência

Modelo de referência (*baseline*)



Modelo treinado



Podemos dizer que o nosso modelo é “bom” porque ele aprendeu (a partir dos dados) a errar menos que o modelo de referência.


No caso do dataset Bank Marketing e o modelo de regressão linear

Referência (sempre 40 anos)

8,4 anos de erro


Regressão linear

6,5 anos de erro



~2 anos a menos


Acertou, ou por quanto errou?



modelo prevê uma classe: *versicolor* → avaliamos se ele **acertou ou errou** → contamos os acertos ao longo de todas as previsões → **acurácia**

k-NN no Iris: **93,3%** · referência (sempre a mesma espécie): **33,3%**

O que o modelo devolve decide como ele é julgado.



50,5 anos para quem tem 55: **acertou?**

não existe "acerto" → medimos a distância entre a previsão e o real para todas as previsões → **erro médio**


A avaliação do modelo depende do que ele devolve

Tarefa	O modelo devolve	Como julgar	Modelo de referência
Classificação	uma categoria	acertou ou errou → acurácia	sempre a categoria mais comum
Regressão	um número	a distância → erro médio	sempre a média

Regressão logística

Um novo modelo para classificação

A ideia de regressão logística



Comparando as performances, qual modelo é melhor?

	Modelo de referência	Modelo treinado
Iris	33,3%	93,3% (k-NN)
Banco	88,7%	88,7% (logística)

$$\text{acurácia da referência} = \frac{7.310 \text{ que disseram não}}{8.238} = \mathbf{88,7\%}$$

Avaliação depende do objetivo

O que o banco quer com esse modelo?




Achar o perfil de quem aceitaria o investimento, para ligar prioritariamente para essas pessoas.

928 pessoas do teste aceitaram.

A regressão logística achou **ZERO**.

Mas o corte que define o resultado da regressão logística é algo que a gente pode alterar — vamos baixá-lo!



corte: **20%**


A matriz de confusão

Detalhando os tipos de erro de um modelo

Avaliando o modelo

		Classe prevista	
		Não vai aceitar o investimento	Vai aceitar o investimento
Classe real	Não aceitou	6.998	312 ligação inútil
	Aceitou	793 venda perdida	135


Para o projeto de vocês:



Qual modelo de referência
faz sentido pros dados e
pro problema?



Quais medidas de
performance do modelo
deveriam ser priorizadas?



Pra decisão do
modelo de vocês, qual
tipo de erro seria pior?