

Árvores de decisão


Um modelo feito de perguntas de sim ou não

Mateus Levi Simões Fernandes

Aula 4 · 24/09/2026

Aprendizado de Máquina (APMAI) · IASEG


Um novo tipo de problema




Onde vocês passariam uma linha para separar as duas classes/cores?

Uma linha contra perguntas de sim ou não

regressão logística: 49,0%




árvore, profundidade 3: 95,3%




Uma linha contra perguntas de sim ou não

regressão logística: 49,0%




árvore, profundidade 3: 95,3%



- **Regressão logística:** uma soma com pesos $\rightarrow$ no plano, uma linha. Acerta o mesmo que o chute (50%).

Uma linha contra perguntas de sim ou não




- **Regressão logística:** uma soma com pesos $\rightarrow$ no plano, uma linha. Acerta o mesmo que o chute (50%).
- **Árvore:** perguntas de sim ou não, uma coluna de cada vez.

O que a árvore faz: cada pergunta corta o plano em dois


profundidade 1: 53,7%




profundidade 2: 68,0%



profundidade 3: 95,3%



O que a árvore faz: cada pergunta corta o plano em dois



- Cada pergunta usa **uma coluna** e um valor: “a coluna 1 é menor que tal valor?”
- Por isso os cortes são sempre **retos**
- **Profundidade** = quantas perguntas seguidas

Vocês já viram uma árvore

Aula 1: aprovação de empréstimo em um banco.

Escrita por um especialista

- saldo da conta negativo?
- renda maior que 5.000?

Aprendida dos dados

- dívida/renda maior que 0,4?
- *credit score* maior que 680?
- ...

Vocês já viram uma árvore

Aula 1: aprovação de empréstimo em um banco.

Escrita por um especialista


- saldo da conta negativo?
- renda maior que 5.000?

Aprendida dos dados


- dívida/renda maior que 0,4?
- *credit score* maior que 680?
- ...

Aquilo era uma **árvore de decisão**: o algoritmo escolhe **as perguntas** e **os valores** a partir dos dados.

A árvore no Titanic, com duas perguntas



A árvore no Titanic, com duas perguntas



Contagens dos 499 passageiros do treino.

O que a árvore **guarda** depois de treinar: **as perguntas** e a resposta de cada folha.

Como ela responde a um caso novo

Uma passageira nova: **mulher, 2ª classe.**

- é mulher? **sim** → está na 1ª ou 2ª classe? **sim** → folha: 107 de 113 → **sobreviveu**

Como ela responde a um caso novo

Uma passageira nova: **mulher, 2ª classe**.

- é mulher? **sim** → está na 1ª ou 2ª classe? **sim** → folha: 107 de 113 → **sobreviveu**

Cada folha guarda uma **proporção**, ou seja, uma chance:

- a resposta sai de um **corte em 50%**, como na regressão logística
- mulher na 3ª classe: 30 de 66 (45%) → não sobreviveu

Como ela responde a um caso novo

Uma passageira nova: **mulher, 2ª classe**.

- é mulher? **sim** → está na 1ª ou 2ª classe? **sim** → folha: 107 de 113 → **sobreviveu**

Cada folha guarda uma **proporção**, ou seja, uma chance:

- a resposta sai de um **corte em 50%**, como na regressão logística
- mulher na 3ª classe: 30 de 66 (45%) → não sobreviveu

	Treino	Teste
Árvore, duas perguntas	79,6%	78,1%
Referência (sempre “não”)	59,3%	59,5%

O que cada modelo guarda, e como responde

Modelo	Guarda depois de treinar	Responde a um caso novo
Referência	um valor só	sempre a mesma resposta
kNN	todos os dados de treino	olha os vizinhos
Regressão linear	um peso por coluna	faz uma soma
Regressão logística	um peso por coluna	soma → chance → corte

O que cada modelo guarda, e como responde

Modelo	Guarda depois de treinar	Responde a um caso novo
Referência	um valor só	sempre a mesma resposta
kNN	todos os dados de treino	olha os vizinhos
Regressão linear	um peso por coluna	faz uma soma
Regressão logística	um peso por coluna	soma → chance → corte
Árvore	as perguntas e as folhas	segue o caminho

A árvore não precisa de escala

Titanic, acurácia no teste	Sem escala	Com escala
kNN ($k = 5$)	65,1%	77,7%
Árvore, duas perguntas	78,1%	78,1%

A árvore não precisa de escala

Titanic, acurácia no teste	Sem escala	Com escala
kNN ($k = 5$)	65,1%	77,7%
Árvore, duas perguntas	78,1%	78,1%

- A árvore pergunta sobre **uma coluna de cada vez**: mudar a unidade não muda a resposta

A árvore não precisa de escala

Titanic, acurácia no teste	Sem escala	Com escala
kNN ($k = 5$)	65,1%	77,7%
Árvore, duas perguntas	78,1%	78,1%

- A árvore pergunta sobre **uma coluna de cada vez**: mudar a unidade não muda a resposta
- E a primeira pergunta dela é **sexo**: justamente a coluna que o kNN sem escala ignorava

Os botões da árvore

- `max_depth`: quantas perguntas seguidas a árvore pode fazer
- `min_samples_leaf`: quantos casos cada folha precisa ter, no mínimo

Os botões da árvore

- `max_depth`: quantas perguntas seguidas a árvore pode fazer
- `min_samples_leaf`: quantos casos cada folha precisa ter, no mínimo

Como o k do kNN: **quem escolhe é quem modela.**

Os botões da árvore

- `max_depth`: quantas perguntas seguidas a árvore pode fazer
- `min_samples_leaf`: quantos casos cada folha precisa ter, no mínimo

Como o k do kNN: **quem escolhe é quem modela.**

E se não colocarmos limite nenhum?

No código

```
from sklearn.tree import DecisionTreeClassifier, plot_tree

arvore = DecisionTreeClassifier(max_depth=2, random_state=42)
arvore.fit(X_train, y_train)

arvore.score(X_train, y_train)      # acurácia no treino
arvore.score(X_test, y_test)       # acurácia no teste

plot_tree(arvore, feature_names=X_train.columns,
          class_names=['não', 'sim'], filled=True)
```

No código

```
from sklearn.tree import DecisionTreeClassifier, plot_tree

arvore = DecisionTreeClassifier(max_depth=2, random_state=42)
arvore.fit(X_train, y_train)

arvore.score(X_train, y_train)      # acurácia no treino
arvore.score(X_test, y_test)       # acurácia no teste

plot_tree(arvore, feature_names=X_train.columns,
          class_names=['não', 'sim'], filled=True)
```

- `random_state=42`: a árvore também tem sorteios internos (desempates); fixar para reproduzir
- `plot_tree`: desenha as perguntas e as folhas

A árvore também faz regressão

- Em vez de uma proporção, cada folha guarda uma **média**
- `DecisionTreeRegressor`, com os mesmos botões

A árvore também faz regressão

- Em vez de uma proporção, cada folha guarda uma **média**
- `DecisionTreeRegressor`, com os mesmos botões

No mapa: a árvore serve à **classificação** e à **regressão**, como o kNN.

Mão na massa: uma árvore no notebook do Iris

No notebook da aula 1 (01_Pipeline_ML_Iris), trocar o kNN por uma árvore:

1. **Etapa 5:** trocar o kNN pela árvore

```
from sklearn.tree import DecisionTreeClassifier  
modelo = DecisionTreeClassifier(random_state=42)  
modelo.fit(X_train, y_train)
```

2. **Etapa 6 e flor nova:** trocar knn por modelo
3. Rodar tudo até o fim
4. Acrescentar: `modelo.score(X_train, y_train)`

Mão na massa: uma árvore no notebook do Iris

No notebook da aula 1 (01_Pipeline_ML_Iris), trocar o kNN por uma árvore:

1. **Etapas 5:** trocar o kNN pela árvore

```
from sklearn.tree import DecisionTreeClassifier  
modelo = DecisionTreeClassifier(random_state=42)  
modelo.fit(X_train, y_train)
```

2. **Etapas 6 e flor nova:** trocar knn por modelo
3. Rodar tudo até o fim
4. Acrescentar: `modelo.score(X_train, y_train)`

Anotem: acurácia no **teste**, no **treino**, e a espécie da flor nova.

Iris (30 flores no teste)	Treino	Teste
kNN, $k = 3$ (aula 1)	95,8%	93,3%
Árvore, sem limite	100%	93,3%

Iris (30 flores no teste)	Treino	Teste
kNN, $k = 3$ (aula 1)	95,8%	93,3%
Árvore, sem limite	100%	93,3%
Árvore, <code>max_depth=3</code>	98,3%	96,7%

Flor nova: **setosa**, igual ao kNN.

Iris (30 flores no teste)	Treino	Teste
kNN, $k = 3$ (aula 1)	95,8%	93,3%
Árvore, sem limite	100%	93,3%
Árvore, <code>max_depth=3</code>	98,3%	96,7%

Flor nova: **setosa**, igual ao kNN.

100% no treino, 93,3% no teste: a árvore aprendeu, ou decorou?

Extra: as quatro nuvens e o primeiro inverno da IA

- As quatro nuvens são o problema do **OU exclusivo** (XOR): uma cor quando só uma das colunas é alta
- **Perceptron** (Rosenblatt, 1958): um neurônio artificial, que no plano é uma linha
- **Minsky e Papert** (1969): uma linha sozinha não resolve o XOR
- Isso ajudou a esfriar o interesse em redes neurais nos anos 1970: parte do **primeiro inverno da IA** (aula 1)

Extra: poda

- Deixar a árvore crescer e depois **cortar os galhos** que quase não melhoram o acerto
- No scikit-learn: **ccp_alpha** (quanto maior, mais galhos cortados)
- Mesmo objetivo de **max_depth** e **min_samples_leaf**: impedir que a árvore **decore** o treino