

Aprende, decorou, ou não aprendeu o suficiente?


Sobreajuste e subajuste

Mateus Levi Simões Fernandes


Aula 4 · 24/09/2026

Aprendizado de Máquina (APMAI) · IASEG

Sem limite: uma árvore para decorar o treino



Sem limite: uma árvore para decorar o treino



- Titanic, sem `max_depth`: profundidade 15, **109 folhas** para 499 passageiros
- Treino **99,4%** · teste **74,9%**

O que é decorar

O treino tem um **padrão** (mulheres e a 1ª classe sobreviveram mais) e tem **acaso** (aquele passageiro específico que fugiu à regra).

O que é decorar

O treino tem um **padrão** (mulheres e a 1ª classe sobreviveram mais) e tem **acaso** (aquele passageiro específico que fugiu à regra).

- Um modelo que **aprende** pega o padrão
- Um modelo que **decora** pega o padrão e o acaso

O que é decorar

O treino tem um **padrão** (mulheres e a 1ª classe sobreviveram mais) e tem **acaso** (aquele passageiro específico que fugiu à regra).

- Um modelo que **aprende** pega o padrão
- Um modelo que **decora** pega o padrão e o acaso

O acaso do treino não se repete nos casos novos: por isso o teste cai.

O que é decorar

O treino tem um **padrão** (mulheres e a 1ª classe sobreviveram mais) e tem **acaso** (aquele passageiro específico que fugiu à regra).


- Um modelo que **aprende** pega o padrão
- Um modelo que **decora** pega o padrão e o acaso

O acaso do treino não se repete nos casos novos: por isso o teste cai.


Nome: sobreajuste (*overfitting*).

Nas quatro nuvens, profundidade por profundidade


profundidade 1
treino 53,6% · teste 53,7%




profundidade 3
treino 96,7% · teste 95,3%



sem limite
treino 100,0% · teste 92,0%




Nas quatro nuvens, profundidade por profundidade




- **Profundidade 1:** uma pergunta não basta; treino e teste perto do chute (50%)

Nas quatro nuvens, profundidade por profundidade


profundidade 1
treino 53,6% · teste 53,7%



profundidade 3
treino 96,7% · teste 95,3%




sem limite
treino 100,0% · teste 92,0%




- **Profundidade 1:** uma pergunta não basta; treino e teste perto do chute (50%)
- **Profundidade 3:** pegou o padrão das quatro nuvens

Nas quatro nuvens, profundidade por profundidade


profundidade 1
treino 53,6% · teste 53,7%



profundidade 3
treino 96,7% · teste 95,3%




sem limite
treino 100,0% · teste 92,0%



- **Profundidade 1:** uma pergunta não basta; treino e teste perto do chute (50%)
- **Profundidade 3:** pegou o padrão das quatro nuvens
- **Sem limite:** ilhas em volta de pontos soltos: decorou

A curva: treino e teste conforme a árvore cresce



Quatro nuvens: 700 pontos no treino, 300 no teste.

Os dois jeitos de errar

	Treino	Teste	
Simples demais	baixo	baixo, perto do treino	subajuste (<i>underfitting</i>)

Os dois jeitos de errar

	Treino	Teste	
Simples demais	baixo	baixo, perto do treino	subajuste (<i>underfitting</i>)
Aprendeu	bom	bom, perto do treino	

Os dois jeitos de errar

	Treino	Teste	
Simples demais	baixo	baixo, perto do treino	subajuste (<i>underfitting</i>)
Aprendeu	bom	bom, perto do treino	
Decorou	muito alto	bem abaixo do treino	sobreajuste (<i>overfitting</i>)

Os dois jeitos de errar

	Treino	Teste	
Simples demais	baixo	baixo, perto do treino	subajuste (<i>underfitting</i>)
Aprendeu	bom	bom, perto do treino	
Decorou	muito alto	bem abaixo do treino	sobreajuste (<i>overfitting</i>)

Treino e teste **perto um do outro não basta**: com profundidade 1, os dois estavam perto, e perto do chute.

Padrão: olhar treino, teste e referência juntos.

A curva do Titanic, construída pela turma

No notebook `04_Arvores_aluno`, Parte 4:

1. Cada um recebe uma profundidade: 1, 2, 3, 4, 5, 6, 8, 10, 12, 15 ou **None** (sem limite)
2. Troque o `___` em `profundidade = ___` e rode a célula
3. Diga os dois números: **treino** e **teste**


A curva do Titanic, construída pela turma

No notebook `04_Arvores_aluno`, Parte 4:

1. Cada um recebe uma profundidade: 1, 2, 3, 4, 5, 6, 8, 10, 12, 15 ou **None** (sem limite)
2. Troque o `___` em `profundidade = ___` e rode a célula
3. Diga os dois números: **treino** e **teste**

Antes de rodar: **conforme a árvore cresce, o treino sobe ou desce? E o teste?**

A curva do Titanic



499 passageiros no treino, 215 no teste. Referência: sempre “não sobreviveu”, 59,5%.

Lendo as duas pontas

- À direita: treino 99,4%, teste 74,9% → decorou

Lendo as duas pontas

- À direita: treino 99,4%, teste 74,9% → decorou
- À esquerda: uma pergunta só (“é mulher?”) já acerta 77,2%, bem acima da referência
 - a *feature* gênero é muito forte para esse problema, logo uma árvore rasa já aprende bem
 - treino e teste perto, os dois abaixo do que poderiam

Lendo as duas pontas


- **À direita:** treino 99,4%, teste 74,9% → decorou
- **À esquerda:** uma pergunta só (“é mulher?”) já acerta 77,2%, bem acima da referência
 - a *feature* gênero é muito forte para esse problema, logo uma árvore rasa já aprende bem
 - treino e teste perto, os dois abaixo do que poderiam
- **No meio:** o melhor teste desta divisão foi com profundidade 5 (82,8%)

Lendo as duas pontas


- À direita: treino 99,4%, teste 74,9% → decorou
- À esquerda: uma pergunta só (“é mulher?”) já acerta 77,2%, bem acima da referência
 - a *feature* gênero é muito forte para esse problema, logo uma árvore rasa já aprende bem
 - treino e teste perto, os dois abaixo do que poderiam
- No meio: o melhor teste desta divisão foi com profundidade 5 (82,8%)

Então a resposta é profundidade 5?

O melhor ponto depende do sorteio



O melhor ponto depende do sorteio



- Na média de 20 sorteios, as profundidades de 1 a 8 quase **empatam** (78,7% a 80,1%)
- A “melhor” profundidade mudou de sorteio para sorteio: **de 1 a 15**

Como dá errado

- Olhar **só o treino** favorece modelos que decoram o padrão dos dados de treino

Como dá errado

- Olhar **só o treino** favorece modelos que decoram o padrão dos dados de treino
- Achar que treino e teste perto é sempre bom: pode ser que **não aprendeu**

Como dá errado

- Olhar **só o treino** favorece modelos que decoram o padrão dos dados de treino
- Achar que treino e teste perto é sempre bom: pode ser que **não aprendeu**
- Escolher a profundidade **olhando o teste**: o teste vira parte da escolha, e deixa de ser juiz

Como dá errado

- Olhar **só o treino** favorece modelos que decoram o padrão dos dados de treino
- Achar que treino e teste perto é sempre bom: pode ser que **não aprendeu**
- Escolher a profundidade **olhando o teste**: o teste vira parte da escolha, e deixa de ser juiz

Aula 5: validação cruzada, para escolher sem usar o teste.

1. Mostrar **treino, teste e referência** lado a lado
2. Dizer em que **zona** o modelo está: simples demais, aprendeu, ou decorou
3. Começar com uma árvore **rasa** e aumentar aos poucos
4. Na dúvida entre duas profundidades parecidas, ficar com a **mais simples**
5. Não escolher olhando o teste

Aprendeu, decorou, ou não aprendeu o suficiente?

Treino	Teste	Leitura
perto da referência	perto da referência	não aprendeu o suficiente
bom	bom, perto do treino	aprendeu
muito alto	bem abaixo do treino	decorou

Aprendeu, decorou, ou não aprendeu o suficiente?

Treino	Teste	Leitura
perto da referência	perto da referência	não aprendeu o suficiente
bom	bom, perto do treino	aprendeu
muito alto	bem abaixo do treino	decorou

Pergunta 7 da arguição: *como vocês sabem que o modelo não decorou os dados de treino, e como sabem que ele aprendeu alguma coisa?*

- não decorou: a **distância entre treino e teste**
- aprendeu alguma coisa: a **distância até a referência**

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	
C	Iris	árvore sem limite	100,0	93,3	33,3	
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	
C	Iris	árvore sem limite	100,0	93,3	33,3	
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	decorou
C	Iris	árvore sem limite	100,0	93,3	33,3	
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	decorou
C	Iris	árvore sem limite	100,0	93,3	33,3	aprendeu
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	decorou
C	Iris	árvore sem limite	100,0	93,3	33,3	aprendeu
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	não aprendeu
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	decorou
C	Iris	árvore sem limite	100,0	93,3	33,3	aprendeu
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	não aprendeu
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	decorou
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	

Rodada: em que zona está cada modelo?

Em duplas: para cada linha, a **zona** e o **porquê**.

	Dados	Modelo	Treino	Teste	Referência	Zona
A	Quatro nuvens	regressão logística	50,0	49,0	50,0	não aprendeu
B	Titanic	kNN, $k = 1$	99,4	63,3	59,5	decorou
C	Iris	árvore sem limite	100,0	93,3	33,3	aprendeu
D	Titanic	árvore, só sibsp e parch , prof. 2	64,9	61,9	59,5	não aprendeu
E	Titanic	árvore, só fare , sem limite	82,4	66,5	59,5	decorou
F	Quatro nuvens	árvore, prof. 3	96,7	95,3	50,0	aprendeu

O que a rodada mostra

- C: 100% no treino não é o problema; a distância até o teste é pequena (2 flores de 30)

O que a rodada mostra

- **C**: 100% no treino não é o problema; a distância até o teste é pequena (2 flores de 30)
- **A** e **D**: treino e teste perto, mas os dois perto da referência
 - em D, o culpado não é o modelo: as colunas dizem pouco

O que a rodada mostra

- **C**: 100% no treino não é o problema; a distância até o teste é pequena (2 flores de 30)
- **A** e **D**: treino e teste perto, mas os dois perto da referência
 - em D, o culpado não é o modelo: as colunas dizem pouco
- **B** e **E**: os dois decoraram, mas E ainda ficou 7 pontos acima da referência; B, menos de 4

O que a rodada mostra

- **C**: 100% no treino não é o problema; a distância até o teste é pequena (2 flores de 30)
- **A** e **D**: treino e teste perto, mas os dois perto da referência
 - em D, o culpado não é o modelo: as colunas dizem pouco
- **B** e **E**: os dois decoraram, mas E ainda ficou 7 pontos acima da referência; B, menos de 4

Sempre as duas distâncias: de treino para teste, e de teste para referência.

Para o projeto

No relatório:

- **Seção 3:** a tabela ganha uma linha: referência, o modelo da aula 3, a árvore; treino e teste de cada um
- **Seção 5:** em que zona o modelo está, e o quanto isso depende da divisão

Para o projeto

No relatório:

- **Seção 3:** a tabela ganha uma linha: referência, o modelo da aula 3, a árvore; treino e teste de cada um
- **Seção 5:** em que zona o modelo está, e o quanto isso depende da divisão

Sugestão: treinar uma árvore no dataset de vocês, anotar treino e teste ao lado da referência, e dizer em que ponta da curva o modelo está.

Para o projeto

No relatório:

- **Seção 3:** a tabela ganha uma linha: referência, o modelo da aula 3, a árvore; treino e teste de cada um
- **Seção 5:** em que zona o modelo está, e o quanto isso depende da divisão

Sugestão: treinar uma árvore no dataset de vocês, anotar treino e teste ao lado da referência, e dizer em que ponta da curva o modelo está.

Aula 5 (29/09): muitas árvores em vez de uma (*random forest*), e validação cruzada: e se a divisão tivesse sido outra?