

Como se melhora um modelo, e qual é o custo disso?

Validação cruzada, floresta aleatória, comparação de modelos e vazamento

Mateus Levi Simões Fernandes

Aula 5 · 29/09/2026

Aprendizado de Máquina (APMAI) · IASEG

Datas confirmadas: entrega do relatório 02/10, 23h59 · apresentação e perguntas 05/10.

Datas confirmadas: entrega do relatório 02/10, 23h59 · apresentação e perguntas 05/10.


A pergunta da manhã:

Como se melhora um modelo, e qual é o custo disso?


As sete etapas



As sete etapas



As sete etapas



As sete etapas




As sete etapas




As sete etapas



As sete etapas



As sete etapas



O que já vimos (1 a 4)

- **1. Definição do problema:** o tipo de problema (classificação, regressão, agrupamento); a resposta está escrita nos dados? (supervisionado ou não supervisionado);

O que já vimos (1 a 4)

- **1. Definição do problema:** o tipo de problema (classificação, regressão, agrupamento); a resposta está escrita nos dados? (supervisionado ou não supervisionado);
- **2. Preparação dos dados:** vazios e “unknown”; colunas repetidas; uma coluna que é a própria resposta (**a**live); texto que vira 0 e 1;

O que já vimos (1 a 4)

- **1. Definição do problema:** o tipo de problema (classificação, regressão, agrupamento); a resposta está escrita nos dados? (supervisionado ou não supervisionado);
- **2. Preparação dos dados:** vazios e “unknown”; colunas repetidas; uma coluna que é a própria resposta (**a**live); texto que vira 0 e 1;
- **3. Divisão treino/teste:** o treino mostra o quanto o modelo se ajustou; o teste estima casos novos; **stratify**; o tamanho do teste; **a nota do teste depende do sorteio** (o erro do notebook);

O que já vimos (1 a 4)

- **1. Definição do problema:** o tipo de problema (classificação, regressão, agrupamento); a resposta está escrita nos dados? (supervisionado ou não supervisionado);
- **2. Preparação dos dados:** vazios e “unknown”; colunas repetidas; uma coluna que é a própria resposta (**alive**); texto que vira 0 e 1;
- **3. Divisão treino/teste:** o treino mostra o quanto o modelo se ajustou; o teste estima casos novos; **stratify**; o tamanho do teste; **a nota do teste depende do sorteio** (o erro do notebook);
- **4. Pré-processamento:** a escala, e por que o kNN precisa dela e a árvore não.

O que já vimos (5 a 7)

- **5. Treinamento:** kNN, regressão linear, regressão logística, árvore; os hiperparâmetros (k , profundidade); sobreajuste e subajuste;

O que já vimos (5 a 7)

- **5. Treinamento:** kNN, regressão linear, regressão logística, árvore; os hiperparâmetros (k , profundidade); sobreajuste e subajuste;
- **6. Predição:** como cada modelo responde a um caso novo (vizinhos, soma, chance e corte, caminho até a folha); o corte é uma escolha;

O que já vimos (5 a 7)

- **5. Treinamento:** kNN, regressão linear, regressão logística, árvore; os hiperparâmetros (k , profundidade); sobreajuste e subajuste;
- **6. Predição:** como cada modelo responde a um caso novo (vizinhos, soma, chance e corte, caminho até a folha); o corte é uma escolha;
- **7. Avaliação:** a métrica depende do que o modelo devolve (acurácia ou erro médio); sempre contra a referência; a matriz de confusão e os dois tipos de erro.

Para começar: em que zona está este modelo?

Titanic, uma árvore **só com a tarifa**, sem limite de profundidade:

Treino	Teste	Referência
82,4%	66,5%	59,5%

Simples demais, aprendeu, ou decorou?


Para começar: em que zona está este modelo?

Titanic, uma árvore **só com a tarifa**, sem limite de profundidade:

Treino	Teste	Referência
82,4%	66,5%	59,5%

Simples demais, aprendeu, ou decorou?

Decorou: 16 pontos entre treino e teste, mas está melhor do que a referência (então alguma coisa aprendeu).



- 3 e 7: medir sem depender de um sorteio só (validação cruzada), e comparar modelos direito;
- 5: um modelo novo, a floresta aleatória, e escolher os hiperparâmetros sem olhar o teste;
- E no fim voltamos à 2: colunas que o modelo não deveria ter.

Mão na massa: cada um com o seu sorteio

1. Abram o `05_Comparando_Modelos_aluno` (está no EAD) no Colab;
2. Rodem a **Parte 1** inteira (carrega o Titanic e faz a divisão de todos);
3. Na Parte 2, escrevam **um número inteiro qualquer** em:

```
| meu_sorteio = ___
```


4. Rodem, e **digam o número do teste** para o quadro.

Todos devem usar a mesma árvore (profundidade 5); só vamos mudar o sorteio.

Validação cruzada


Cada divisão de teste gera uma nota diferente

A mesma árvore (profundidade 5), os mesmos 714 passageiros do Titanic. Só muda o **sorteio** que separa treino e teste:



Cada divisão de teste gera uma nota diferente


A mesma árvore (profundidade 5), os mesmos 714 passageiros do Titanic. Só muda o **sorteio** que separa treino e teste:



Qual desses números é “a nota” da árvore?

Cada divisão de teste gera uma nota diferente

A mesma árvore (profundidade 5), os mesmos 714 passageiros do Titanic. Só muda o **sorteio** que separa treino e teste:



Qual desses números é “a nota” da árvore? **Nenhum!**

A ideia: cinco simulados em vez de uma prova

Lista de exercícios o treino para aprender	Simulados a validação cruzada para decidir	A prova o teste para julgar, uma vez
--	--	--

A ideia: cinco simulados em vez de uma prova

Lista de exercícios	Simulados	A prova
o treino	a validação cruzada	o teste
para aprender	para decidir	para julgar, uma vez

1. Pegue **só o treino** e corte em 5 partes;
2. Treine em 4 partes e teste na 5ª;
3. Repita até cada parte ter sido o teste uma vez.

A ideia: cinco simulados em vez de uma prova

Lista de exercícios	Simulados	A prova
o treino	a validação cruzada	o teste
para aprender	para decidir	para julgar, uma vez

1. Pegue **só o treino** e corte em 5 partes;
2. Treine em 4 partes e teste na 5ª;
3. Repita até cada parte ter sido o teste uma vez.

Cada caso do treino é testado **exatamente uma vez**. O resultado são **cinco notas**, não uma.

Como funciona

o treino, cortado em 5 partes

simulado 1	testa	treina	treina	treina	treina	nota 1
simulado 2	treina	testa	treina	treina	treina	nota 2
simulado 3	treina	treina	testa	treina	treina	nota 3
simulado 4	treina	treina	treina	testa	treina	nota 4
simulado 5	treina	treina	treina	treina	testa	nota 5

o teste
guardado
para o fim

Como funciona

o treino, cortado em 5 partes


simulado 1	testa	treina	treina	treina	treina	nota 1
simulado 2	treina	testa	treina	treina	treina	nota 2
simulado 3	treina	treina	testa	treina	treina	nota 3
simulado 4	treina	treina	treina	testa	treina	nota 4
simulado 5	treina	treina	treina	treina	testa	nota 5

o teste
guardado
para o fim

Cinco notas → a **média**, a **pior** e a **melhor**. O teste não entra em nenhum simulado.


No Titanic: cinco notas, não uma

Árvore de profundidade 5, treino de 499 passageiros cortado em 5 partes de 100:



No Titanic: cinco notas, não uma


Árvore de profundidade 5, treino de 499 passageiros cortado em 5 partes de 100:



- Média **79,7%**; entre a pior e a melhor parte, **14 pontos**;
- O teste (82,8%) caiu perto da ponta de cima: **foi um sorteio bom**.

No Titanic: cinco notas, não uma

Árvore de profundidade 5, treino de 499 passageiros cortado em 5 partes de 100:



- Média **79,7%**; entre a pior e a melhor parte, **14 pontos**;
- O teste (82,8%) caiu perto da ponta de cima: **foi um sorteio bom**.

No final, treinamos o modelo em **todos** os dados de treino para fazer o teste.

Mão na massa: os seus simulados


1. Na Parte 2, rodem a célula seguinte: ela faz os cinco simulados **no seu sorteio**;
2. Digam **a média** para o quadro, na segunda coluna;
3. Depois, a célula com a divisão de todos: **os mesmos cinco números** para a sala inteira.

Mão na massa: os seus simulados


1. Na Parte 2, rodem a célula seguinte: ela faz os cinco simulados **no seu sorteio**;
2. Digam **a média** para o quadro, na segunda coluna;
3. Depois, a célula com a divisão de todos: **os mesmos cinco números** para a sala inteira.

Antes de ver o quadro: **de pessoa para pessoa, a média vai variar mais ou menos que o teste?**

A média de cinco simulados balança menos



A média de cinco simulados balança menos



Mesmos 20 sorteios: o teste vai de 76,3% a 84,7%; a média dos simulados, de 76,1% a 81,6%. E as cinco notas dizem **o quanto o resultado depende da divisão.**

```
from sklearn.model_selection import cross_val_score

arvore = DecisionTreeClassifier(max_depth=5, random_state=42)
notas = cross_val_score(arvore, X_train, y_train, cv=5)    # só o treino

print(notas)                                                # as cinco notas
print(notas.mean(), notas.min(), notas.max())              # média, pior, melhor
```

```
from sklearn.model_selection import cross_val_score

arvore = DecisionTreeClassifier(max_depth=5, random_state=42)
notas = cross_val_score(arvore, X_train, y_train, cv=5)    # só o treino

print(notas)                                                # as cinco notas
print(notas.mean(), notas.min(), notas.max())              # média, pior, melhor
```

- `cv=5`: cinco partes;
- Em classificação, cada parte mantém a proporção das classes (a ideia do **stratify**, de novo).

- Reportar só a média: **a faixa** (pior e melhor) é metade da resposta;

Erros comuns na validação cruzada

- Reportar só a média: **a faixa** (pior e melhor) é metade da resposta;
- Fazer a validação cruzada com **todos** os dados, teste incluído: o teste já foi usado;

Erros comuns na validação cruzada

- Reportar só a média: **a faixa** (pior e melhor) é metade da resposta;
- Fazer a validação cruzada com **todos** os dados, teste incluído: o teste já foi usado;
- Achar que ela **substitui** o teste: os simulados escolhem; a prova ainda julga, uma vez;

Erros comuns na validação cruzada

- Reportar só a média: **a faixa** (pior e melhor) é metade da resposta;
- Fazer a validação cruzada com **todos** os dados, teste incluído: o teste já foi usado;
- Achar que ela **substitui** o teste: os simulados escolhem; a prova ainda julga, uma vez;
- Aprender a escala **antes**, com o treino inteiro: cada simulado tem que aprender a sua.


1. Dividir treino e teste **antes de tudo**;
2. Validação cruzada **só no treino**, com $cv=5$;
3. Reportar a **média**, a **pior** e a **melhor** parte;
4. O teste fica para o fim, **uma vez**.

1. Dividir treino e teste **antes de tudo**;
2. Validação cruzada **só no treino**, com $cv=5$;
3. Reportar a **média**, a **pior** e a **melhor** parte;
4. O teste fica para o fim, **uma vez**.

A validação cruzada resolve a **medida**. E o **modelo**: dá para ele mesmo depender menos de um sorteio?

Floresta aleatória


De volta à árvore sem limite



Titanic, árvore sem `max_depth`:

- 109 folhas para 499 passageiros;
- Treino 99,4% · teste 74,9%.

De volta à árvore sem limite




Titanic, árvore sem `max_depth`:

- 109 folhas para 499 passageiros;
- Treino 99,4% · teste 74,9%.

49 folhas existem por causa de um passageiro só.

De volta à árvore sem limite



Titanic, árvore sem `max_depth`:

- 109 folhas para 499 passageiros;
- Treino 99,4% · teste 74,9%.

49 folhas existem por causa de **um passageiro só**.

Folhas feitas para um caso esquisito: a árvore ficou **específica demais** para o treino.

Dois jeitos de sair disso

1. Deixar a árvore mais simples

- limitar a profundidade;
- menos perguntas, folhas maiores.

Dois jeitos de sair disso

1. Deixar a árvore mais simples

- limitar a profundidade;
- menos perguntas, folhas maiores.

2. Manter as árvores específicas, mas fazer muitas

- cada uma treinada num **sorteio diferente** dos casos;
- na hora de responder, **todas votam**.

Dois jeitos de sair disso

1. Deixar a árvore mais simples

- limitar a profundidade;
- menos perguntas, folhas maiores.


2. Manter as árvores específicas, mas fazer muitas

- cada uma treinada num **sorteio diferente** dos casos;
- na hora de responder, **todas votam**.


O jeito 2 é a **floresta aleatória** (*random forest*).

Nas quatro nuvens: três árvores e a votação


árvore 1
erra 10,3% do quadrado




árvore 2
erra 8,1% do quadrado




árvore 3
erra 13,1% do quadrado



a votação das 100
erra 2,8% do quadrado




Nas quatro nuvens: três árvores e a votação



- Cada árvore tem ilhas, **em lugares diferentes**; erra de 8% a 13% do quadrado;
- A votação das 100 erra **2,8%**; no teste, **95,3%** contra 92,0% da árvore sem limite.

Nas quatro nuvens: três árvores e a votação



- Cada árvore tem ilhas, **em lugares diferentes**; erra de 8% a 13% do quadrado;
- A votação das 100 erra **2,8%**; no teste, **95,3%** contra 92,0% da árvore sem limite.

Como cem árvores que erram viram uma votação que quase não erra?

Cada árvore, um sorteio diferente

- Cada árvore sorteia seus casos **do treino inteiro**: no Titanic, cerca de **314 dos 499** passageiros, alguns repetidos;
- Homens e mulheres, todas as classes, todas as idades: **toda árvore vê um pouco de tudo**;

Cada árvore, um sorteio diferente

- Cada árvore sorteia seus casos **do treino inteiro**: no Titanic, cerca de **314 dos 499** passageiros, alguns repetidos;
- Homens e mulheres, todas as classes, todas as idades: **toda árvore vê um pouco de tudo**;
- Em cada pergunta, a árvore só pode escolher entre **algumas das colunas**, sorteadas;

Cada árvore, um sorteio diferente

- Cada árvore sorteia seus casos **do treino inteiro**: no Titanic, cerca de **314 dos 499** passageiros, alguns repetidos;
- Homens e mulheres, todas as classes, todas as idades: **toda árvore vê um pouco de tudo**;
- Em cada pergunta, a árvore só pode escolher entre **algumas das colunas**, sorteadas;
- Resultado: cem árvores **parecidas no geral, diferentes nos detalhes**.

Cada árvore, um sorteio diferente

- Cada árvore sorteia seus casos **do treino inteiro**: no Titanic, cerca de **314 dos 499** passageiros, alguns repetidos;
- Homens e mulheres, todas as classes, todas as idades: **toda árvore vê um pouco de tudo**;
- Em cada pergunta, a árvore só pode escolher entre **algumas das colunas**, sorteadas;
- Resultado: cem árvores **parecidas no geral, diferentes nos detalhes**.

Não são especialistas em áreas diferentes: toda árvore responde a todo caso, e todo voto vale o mesmo.

Por que a votação funciona

- O padrão aparece em todo sorteio (mulheres de 1ª e 2ª classe sobreviveram): toda árvore aprende, e elas votam juntas;

Por que a votação funciona

- **O padrão aparece em todo sorteio** (mulheres de 1ª e 2ª classe sobreviveram): toda árvore aprende, e elas votam juntas;
- **A folha feita para um caso esquisito** (as ilhas) só existe nas árvores que sortearam aquele caso, e cai num lugar diferente em cada uma.

Por que a votação funciona

- **O padrão aparece em todo sorteio** (mulheres de 1ª e 2ª classe sobreviveram): toda árvore aprende, e elas votam juntas;
- **A folha feita para um caso esquisito** (as ilhas) só existe nas árvores que sortearam aquele caso, e cai num lugar diferente em cada uma.

Cada árvore exagera numa coisa diferente, e na votação os exageros se cancelam.


Por que a votação funciona

- O padrão aparece em todo sorteio (mulheres de 1ª e 2ª classe sobreviveram): toda árvore aprende, e elas votam juntas;
- A folha feita para um caso esquisito (as ilhas) só existe nas árvores que sortearam aquele caso, e cai num lugar diferente em cada uma.


Cada árvore exagera numa coisa diferente, e na votação os exageros se cancelam.

Como **testemunhas** de um mesmo fato: cada uma viu de um ângulo e lembra alguns detalhes errado, cada uma do seu jeito. Aquilo em que todas concordam é o que dá para confiar.

No Titanic: a votação acerta mais que qualquer árvore




No Titanic: a votação acerta mais que qualquer árvore




- Cada árvore da floresta, sozinha: **72,7%** em média no teste (de 65,6% a 79,1%);
- A votação das 100: **79,5%**, melhor que **todas** elas.

Como ela responde a um caso novo



Uma passageira do teste: **mulher, 1ª classe, 31 anos,**
tarifa 164,87.

Como ela responde a um caso novo




Uma passageira do teste: **mulher**, **1ª classe**, **31 anos**,
tarifa 164,87.

71 das 100 árvores dizem “sobreviveu”

→ a floresta responde **sobreviveu**. (Ela sobreviveu.)

Como ela responde a um caso novo



Uma passageira do teste: **mulher, 1ª classe, 31 anos,** tarifa 164,87.

71 das 100 árvores dizem “sobreviveu”

→ a floresta responde **sobreviveu**. (Ela sobreviveu.)

A folha da árvore guardava uma proporção, cortada em 50%. Na floresta, a proporção é **a dos votos**, cortada em 50%.

Aprende ou decorou?

Titanic	Treino	Teste
Árvore sem limite	99,4%	74,9%
Floresta (100 árvores)	99,4%	79,5%
Referência (sempre “não”)	59,3%	59,5%

Apreendeu ou decorou?

Titanic	Treino	Teste
Árvore sem limite	99,4%	74,9%
Floresta (100 árvores)	99,4%	79,5%
Referência (sempre “não”)	59,3%	59,5%

- No treino, a floresta acerta quase tudo **por construção**: cada árvore acerta os casos que sorteou;

Apreendeu ou decorou?

Titanic	Treino	Teste
Árvore sem limite	99,4%	74,9%
Floresta (100 árvores)	99,4%	79,5%
Referência (sempre “não”)	59,3%	59,5%


- No treino, a floresta acerta quase tudo **por construção**: cada árvore acerta os casos que sorteou;
- Então, para a floresta, **a nota do treino não diz nada**;

Apreendeu ou decorou?


Titanic	Treino	Teste
Árvore sem limite	99,4%	74,9%
Floresta (100 árvores)	99,4%	79,5%
Referência (sempre “não”)	59,3%	59,5%

- No treino, a floresta acerta quase tudo **por construção**: cada árvore acerta os casos que sorteou;
- Então, para a floresta, **a nota do treino não diz nada**;
- Quem julga: os dados que ela **não viu** (o teste, os simulados) e a distância até a referência.

E se o sorteio da divisão fosse outro?



E se o sorteio da divisão fosse outro?



- Melhor que a árvore sem limite em **19 de 20** sorteios;
- Contra a árvore de profundidade 3: 80,3% contra 79,9% na média. **Um empate.**

O que ela guarda, e os hiperparâmetros

O que guarda: as 100 árvores inteiras.

No Titanic, **9.967 folhas** somadas.

O que ela guarda, e os hiperparâmetros

O que guarda: as 100 árvores inteiras.

No Titanic, **9.967 folhas** somadas.

Os hiperparâmetros (o que a gente escolhe; os *parâmetros* são o que o modelo aprende)


- **n_estimators:** quantas árvores;
- **max_depth, min_samples_leaf:** os mesmos da árvore, em cada uma.

O que ela guarda, e os hiperparâmetros

O que guarda: as 100 árvores inteiras.
No Titanic, **9.967 folhas** somadas.

Os hiperparâmetros (o que a gente escolhe; os *parâmetros* são o que o modelo aprende)

- `n_estimators`: quantas árvores;
- `max_depth`, `min_samples_leaf`: os mesmos da árvore, em cada uma.



Mais árvores **não** fazem a floresta decorar mais: depois de umas 50, o teste para de mudar, e só o tempo de treinamento cresce.

- **A interpretação.** A árvore de profundidade 2 tinha 4 folhas e dava para ler em voz alta. A floresta tem 9.967: não dá para seguir um caminho;

- **A interpretação.** A árvore de profundidade 2 tinha 4 folhas e dava para ler em voz alta. A floresta tem 9.967: não dá para seguir um caminho;
- **A nota do treino** deixa de servir para julgar;

- **A interpretação.** A árvore de profundidade 2 tinha 4 folhas e dava para ler em voz alta. A floresta tem 9.967: não dá para seguir um caminho;
- **A nota do treino** deixa de servir para julgar;
- **Nem sempre compensa.** No Titanic, empata com uma árvore rasa;

- **A interpretação.** A árvore de profundidade 2 tinha 4 folhas e dava para ler em voz alta. A floresta tem 9.967: não dá para seguir um caminho;
- **A nota do treino** deixa de servir para julgar;
- **Nem sempre compensa.** No Titanic, empata com uma árvore rasa;
- **Mais lenta** para treinar, e exige mais espaço para guardar.

- **A interpretação.** A árvore de profundidade 2 tinha 4 folhas e dava para ler em voz alta. A floresta tem 9.967: não dá para seguir um caminho;
- **A nota do treino** deixa de servir para julgar;
- **Nem sempre compensa.** No Titanic, empata com uma árvore rasa;
- **Mais lenta** para treinar, e exige mais espaço para guardar.

Simplificar a árvore deixa **um** modelo mais simples. A floresta mantém a especificidade e a cancela na votação, **e paga o preço em complexidade** de leitura, treinamento e armazenamento.

```
from sklearn.ensemble import RandomForestClassifier

floresta = RandomForestClassifier(n_estimators=100, random_state=42)
floresta.fit(X_train, y_train)

floresta.score(X_train, y_train)    # quase 100%, por construção
floresta.score(X_test, y_test)     # este é o que conta
```

```
from sklearn.ensemble import RandomForestClassifier

floresta = RandomForestClassifier(n_estimators=100, random_state=42)
floresta.fit(X_train, y_train)

floresta.score(X_train, y_train)    # quase 100%, por construção
floresta.score(X_test, y_test)     # este é o que conta
```

Para regressão: `RandomForestRegressor`. Cada árvore dá um número, e a floresta tira a média.

Técnicas que aprendemos

	Classificação	Regressão
Referência	a classe mais comum	a média
kNN	✓	✓
Regressão linear	×	✓
Regressão logística	✓	×
Árvore de decisão	✓	✓
Floresta aleatória	✓	✓

Técnicas que aprendemos

	Classificação	Regressão
Referência	a classe mais comum	a média
kNN	✓	✓
Regressão linear	×	✓
Regressão logística	✓	×
Árvore de decisão	✓	✓
Floresta aleatória	✓	✓

Dois nomes que vocês vão ouvir:

- **Gradient boosting:** árvores feitas uma depois da outra, cada uma corrigindo os erros da anterior;
- **SVM:** uma fronteira traçada o mais longe possível das duas classes.

No notebook, **Parte 3**:

1. Quantas folhas da árvore sem limite têm um passageiro só;
2. A floresta: treino e teste;
3. Cada árvore sozinha contra a votação;
4. Os votos para a passageira;
5. Antes de rodar o laço: **com mais árvores, o treino sobe? E o teste?**

Intervalo

Comparar modelos

Para comparar modelos, precisamos garantir que:

Para comparar modelos, precisamos garantir que:

1. **A mesma divisão de dados** tenha sido usada para todos;
2. **A mesma métrica** seja usada para avaliação;
3. **O mesmo modelo de referência** sirva como base.

Para comparar modelos, precisamos garantir que:

1. **A mesma divisão de dados** tenha sido usada para todos;
2. **A mesma métrica** seja usada para avaliação;
3. **O mesmo modelo de referência** sirva como base.

E agora uma regra nova: devemos **escolher olhando os simulados** (validação cruzada), e só depois fazer a prova (usar o teste).

A escala vai dentro do modelo

Logística e kNN precisam das colunas na mesma escala. Na validação cruzada, cada simulado tem que aprender **a sua**:

```
from sklearn.pipeline import make_pipeline

logistica = make_pipeline(StandardScaler(), LogisticRegression())
knn = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=5))
```

A escala vai dentro do modelo

Logística e kNN precisam das colunas na mesma escala. Na validação cruzada, cada simulado tem que aprender **a sua**:

```
from sklearn.pipeline import make_pipeline

logistica = make_pipeline(StandardScaler(), LogisticRegression())
knn = make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=5))
```

`make_pipeline` junta a escala e o modelo num objeto só: quando ele treina, a escala aprende **só nos dados de treino daquela rodada**.

Mão na massa: escolher antes de ver a prova

No notebook, **Parte 4**:

1. Rodem a função e a tabela **sem o teste**;
2. Escolham um modelo e escrevam o motivo:

```
| escolha = '___'  
| motivo = '___'
```

3. **Só então** rodem a célula da prova (a tabela com o teste).

A tabela, sem o teste

Titanic, 499 passageiros no treino, validação cruzada em 5 partes:

Modelo	Treino	Validação cruzada (média)	Pior – melhor parte
Referência	59,3	59,3	59,0 – 60,0
Regressão logística	80,4	80,3	73,7 – 87,0
kNN ($k = 5$)	86,8	80,4	76,0 – 87,0
Árvore, profundidade 3	81,0	78,7	73,7 – 85,0
Floresta	99,4	81,2	74,0 – 91,0

A tabela, sem o teste

Titanic, 499 passageiros no treino, validação cruzada em 5 partes:

Modelo	Treino	Validação cruzada (média)	Pior – melhor parte
Referência	59,3	59,3	59,0 – 60,0
Regressão logística	80,4	80,3	73,7 – 87,0
kNN ($k = 5$)	86,8	80,4	76,0 – 87,0
Árvore, profundidade 3	81,0	78,7	73,7 – 85,0
Floresta	99,4	81,2	74,0 – 91,0

Escolham agora: qual modelo, e por quê?

O motivo não precisa ser o maior número: **legibilidade, simplicidade ou rapidez** também valem, desde que estejam escritos.

A prova: o teste, uma vez


Modelo	Validação cruzada	Teste	Acertos (de 215)
Referência	59,3	59,5	128
Regressão logística	80,3	78,6	169
kNN ($k = 5$)	80,4	77,7	167
Árvore, profundidade 3	78,7	77,7	167
Floresta	81,2	79,5	171

A prova: o teste, uma vez

Modelo	Validação cruzada	Teste	Acertos (de 215)
Referência	59,3	59,5	128
Regressão logística	80,3	78,6	169
kNN ($k = 5$)	80,4	77,7	167
Árvore, profundidade 3	78,7	77,7	167
Floresta	81,2	79,5	171


- Nos quatro modelos, o teste ficou **de 1 a 3 pontos abaixo** da validação cruzada. É normal, não é fracasso;
- O número do teste é o que vai para o relatório!

Lendo a tabela



- Entre os modelos: **2,4 pontos** de diferença na média;
- Entre as partes de cada um: **11 a 17 pontos**.


Lendo a tabela



- Entre os modelos: **2,4 pontos** de diferença na média;
- Entre as partes de cada um: **11 a 17 pontos**.

A diferença entre os modelos é menor que a diferença entre os simulados.

Lendo a tabela



- Entre os modelos: **2,4 pontos** de diferença na média;
- Entre as partes de cada um: **11 a 17 pontos**.

A diferença entre os modelos é menor que a diferença entre os simulados.


Aqui, escolher pelo teste teria dado a mesma floresta. O problema de olhar o teste aparece **na média**, como veremos a seguir.

Qual profundidade escolher?

Escolher a profundidade olhando o teste faz o teste deixar de ser juiz. Como escolher sem olhar?

Qual profundidade escolher?


Escolher a profundidade olhando o teste faz o teste deixar de ser juiz. Como escolher sem olhar?



Profundidade da árvore, escolhida pelos simulados (a faixa cinza vai da pior à melhor parte).

Qual profundidade escolher?

Escolher a profundidade olhando o teste faz o teste deixar de ser juiz. Como escolher sem olhar?




Profundidade da árvore, escolhida pelos simulados (a faixa cinza vai da pior à melhor parte).

- De 2 a 5, praticamente **empate** (79,4 a 79,8);
- Maior média: profundidade 4;
- No empate, a mais simples também vale.

Qual profundidade escolher?

Escolher a profundidade olhando o teste faz o teste deixar de ser juiz. Como escolher sem olhar?



Profundidade da árvore, escolhida pelos simulados (a faixa cinza vai da pior à melhor parte).

- De 2 a 5, praticamente **empate** (79,4 a 79,8);
- Maior média: profundidade 4;
- No empate, a mais simples também vale.

A escolhida vai para a prova, **uma vez**: profundidade 4 dá **80,5%** (a 2, 78,1%).

Mão na massa (opcional): a profundidade de vocês


No notebook, **Parte 5**:

1. Rodem a tabela das profundidades (só simulados);
2. Escolham, **olhando só essa tabela**:

```
| profundidade_escolhida = ___
```

3. Rodem a prova, **uma vez**.


Olhar o teste empresta pontos do juiz



20 sorteios da divisão:

- escolhendo a profundidade **olhando o teste**, o número reportado dá **81,6%**;
- escolhendo **pelos simulados**, o teste intocado dá **79,5%**.

Olhar o teste empresta pontos do juiz




20 sorteios da divisão:

- escolhendo a profundidade **olhando o teste**, o número reportado dá **81,6%**;
- escolhendo **pelos simulados**, o teste intocado dá **79,5%**.

Uns **2 pontos emprestados do juiz**, em 19 dos 20 sorteios.

Olhar o teste empresta pontos do juiz



20 sorteios da divisão:

- escolhendo a profundidade **olhando o teste**, o número reportado dá **81,6%**;
- escolhendo **pelos simulados**, o teste intocado dá **79,5%**.

Uns **2 pontos emprestados do juiz**, em 19 dos 20 sorteios.

A validação cruzada **não acha um modelo melhor**. Ela mantém **honesto** o número final.

```
for profundidade in [1, 2, 3, 4, 5, 6, 8, 10, None]:
    arvore = DecisionTreeClassifier(max_depth=profundidade, random_state=42)
    notas = cross_val_score(arvore, X_train, y_train, cv=5)
    print(profundidade, notas.mean(), notas.min(), notas.max())

# depois de escolher, olhando só o que foi impresso acima:
final = DecisionTreeClassifier(max_depth=4, random_state=42)
final.fit(X_train, y_train)
print(final.score(X_test, y_test))    # a prova, uma vez
```

Erros comuns ao comparar modelos

- Avaliar modelos em **divisões** ou **métricas** diferentes;

Erros comuns ao comparar modelos

- Avaliar modelos em **divisões** ou **métricas** diferentes;
- Tabela de resultados **sem o modelo de referência**;

Erros comuns ao comparar modelos

- Avaliar modelos em **divisões** ou **métricas** diferentes;
- Tabela de resultados **sem o modelo de referência**;
- Olhar o teste, e depois **trocar de modelo** ou **mexer nos hiperparâmetros** até ele subir;

Erros comuns ao comparar modelos

- Avaliar modelos em **divisões** ou **métricas** diferentes;
- Tabela de resultados **sem o modelo de referência**;
- Olhar o teste, e depois **trocar de modelo** ou **mexer nos hiperparâmetros** até ele subir;
- Reportar a média dos simulados como o resultado final: ela ajudou a escolher o modelo, e também é um pouco otimista.

1. Uma divisão, uma métrica, uma referência, **uma tabela**;
2. Escolher pelas colunas da validação cruzada; **escrever a escolha e o porquê**;
3. O teste **uma vez**, no fim, e esse é o número reportado;
4. No empate, o modelo **mais simples** ou **mais legível**.

Vazamento

Um modelo brilhante e inútil

Um modelo pode tirar uma nota ótima e não servir para nada no dia em que for usado, porque recebeu uma informação que **não vai existir** naquele dia.

Um modelo brilhante e inútil

Um modelo pode tirar uma nota ótima e não servir para nada no dia em que for usado, porque recebeu uma informação que **não vai existir** naquele dia.

Duas formas que já apareceram:

- **alive** no Titanic: a resposta escrita de novo;
- a escala aprendida com **todos** os dados: o teste ensinando o treino.

Um modelo brilhante e inútil

Um modelo pode tirar uma nota ótima e não servir para nada no dia em que for usado, porque recebeu uma informação que **não vai existir** naquele dia.

Duas formas que já apareceram:

- **a**live no Titanic: a resposta escrita de novo;
- a escala aprendida com **todos** os dados: o teste ensinando o treino.

A pergunta que resolve: **no momento da decisão, eu teria essa informação?**

O banco: para quem ligar amanhã?

41.188 pessoas para quem um banco ligou; a coluna **y** diz quem aceitou o investimento.

O banco: para quem ligar amanhã?

41.188 pessoas para quem um banco ligou; a coluna **y** diz quem aceitou o investimento.

Um modelo com as seis colunas que descrevem a pessoa (profissão, estado civil, escolaridade, inadimplência, financiamento, empréstimo):

- teste: 8.238 pessoas, das quais **928 aceitaram**;
- o modelo diz “não” para todo mundo: acha **0 das 928**.

O banco: para quem ligar amanhã?

41.188 pessoas para quem um banco ligou; a coluna **y** diz quem aceitou o investimento.

Um modelo com as seis colunas que descrevem a pessoa (profissão, estado civil, escolaridade, inadimplência, financiamento, empréstimo):

- teste: 8.238 pessoas, das quais **928 aceitaram**;
- o modelo diz “não” para todo mundo: acha **0 das 928**.

O banco quer usar um modelo para decidir **para quem ligar amanhã**.

Exercício: o banco sabe isso antes de fazer uma ligação?

Coluna	O que é
age, job, marital, education default, housing, loan	idade, profissão, estado civil, escolaridade inadimplência, financiamento, empréstimo
contact month, day_of_week duration	celular ou fixo mês e dia da semana da ligação quanto tempo a ligação durou, em segundos
campaign	contatos nesta campanha, contando esta ligação
pdays, previous, poutcome	contatos e resultado de campanhas anteriores
euribor3m, nr.employed, ...	indicadores da economia no mês

Para cada linha, respondam **sim, não, ou depende?** Discutiremos em 5 minutos.

- `duration: não`. Só existe depois que a ligação acabou;

- `duration`: **não**. Só existe depois que a ligação acabou;
- `campaign`: **depende** de quando a decisão é tomada (conta a ligação atual). Um bom argumento para qualquer lado é o que importa;

- `duration`: **não**. Só existe depois que a ligação acabou;
- `campaign`: **depende** de quando a decisão é tomada (conta a ligação atual). Um bom argumento para qualquer lado é o que importa;
- `month`, `day_of_week`: sim, se o dia da ligação é escolhido antes;
- A pessoa, as campanhas anteriores, a economia do mês: sim.

E se juntarmos uma coluna?

O mesmo modelo, a mesma divisão, com **uma** coluna a mais: **duration**.

E se juntarmos uma coluna?

O mesmo modelo, a mesma divisão, com **uma** coluna a mais: **duration**.

Colunas	Acurácia	Disse “sim” para	Achou (de 928)
As 6 da pessoa	88,7%	0	0
As 6 + duration	89,5%	322	192

E se juntarmos uma coluna?

O mesmo modelo, a mesma divisão, com **uma** coluna a mais: **duration**.

Colunas	Acurácia	Disse “sim” para	Achou (de 928)
As 6 da pessoa	88,7%	0	0
As 6 + duration	89,5%	322	192

- A acurácia quase não se mexe; a contagem sai do zero;
- **duration** sozinha, numa árvore de profundidade 2, acha 199: **uma coluna vence as seis**.

E se juntarmos uma coluna?


O mesmo modelo, a mesma divisão, com **uma** coluna a mais: **duration**.

Colunas	Acurácia	Disse “sim” para	Achou (de 928)
As 6 da pessoa	88,7%	0	0
As 6 + duration	89,5%	322	192


- A acurácia quase não se mexe; a contagem sai do zero;
- **duration** sozinha, numa árvore de profundidade 2, acha 199: **uma coluna vence as seis**.

Parece o melhor modelo do dia.

Por que funciona



Por que funciona



Ligações com menos de um minuto: 1 “sim” em 4.181. Com mais de dez minutos: 49 em 100.

A duração é o jeito como a ligação foi

- Para saber a duração, o banco **já precisa ter ligado;**
- O modelo “prevê” o resultado da ligação **usando o resultado da ligação;**
- No dia de decidir para quem ligar amanhã, **essa coluna não existe.**

A duração é o jeito como a ligação foi

- Para saber a duração, o banco **já precisa ter ligado**;
- O modelo “prevê” o resultado da ligação **usando o resultado da ligação**;
- No dia de decidir para quem ligar amanhã, **essa coluna não existe**.

E o jeito mais comum de cair nisso não é escolher **duration** de propósito: é **treinar com todas as colunas da base**, e ela entra junto.

As formas de vazamento

Forma	Exemplo
Uma coluna que é a resposta escrita de novo	alive no Titanic
Uma coluna que só existe depois do fato	duration no banco
Algo aprendido com todos os dados antes de dividir	a escala; preencher vazios com a média da base inteira
O teste usado para escolher	escolher a profundidade olhando o teste

1. Para cada coluna: **no momento da decisão, eu teria essa informação?**
2. Um resultado **bom demais** é motivo para procurar vazamento, não para comemorar;
3. Tudo que aprende com os dados aprende **só no treino** (e dentro de cada simulado);
4. O teste, **uma vez**, no fim.

No notebook, **Parte 6**:

1. O modelo da Aula 3: quantos ele acha?
2. Antes de rodar: **e com a coluna `duration`?**
3. A tabela das faixas de duração;
4. A decisão: que coluna sai?

```
| X_honesto = X_com_duracao.drop(columns=___)
```

Extra: o tempo também vaza

- As colunas da economia mudam **mês a mês**, e as ligações do banco vão de um ano a outro;
- Uma divisão sorteadamente misturada **passado e futuro**: o modelo treina com meses que vêm depois dos que ele testa;

Extra: o tempo também vaza

- As colunas da economia mudam **mês a mês**, e as ligações do banco vão de um ano a outro;
- Uma divisão sorteada mistura **passado e futuro**: o modelo treina com meses que vêm depois dos que ele testa;
- Se o modelo vai ser usado nas ligações do **mês que vem**, o teste honesto são os **últimos meses**, não um sorteio.

Fechamento

Como se melhora um modelo, e qual é o custo disso?

1. **A leitura.** No Titanic, a floresta empata com uma árvore rasa, e custa todas as folhas que dava para ler ($4 \rightarrow 9.967$);

Como se melhora um modelo, e qual é o custo disso?

1. **A leitura.** No Titanic, a floresta empata com uma árvore rasa, e custa todas as folhas que dava para ler ($4 \rightarrow 9.967$);
2. **Um número melhor que é sorte.** Um sorteio só; os simulados mostram a faixa;

Como se melhora um modelo, e qual é o custo disso?

1. **A leitura.** No Titanic, a floresta empata com uma árvore rasa, e custa todas as folhas que dava para ler ($4 \rightarrow 9.967$);
2. **Um número melhor que é sorte.** Um sorteio só; os simulados mostram a faixa;
3. **Um número melhor que é trapaça.** Escolher olhando o teste (uns 2 pontos emprestados), ou uma coluna que vaza ($0 \rightarrow 192$).

No relatório

- **Seção 3:** a tabela de comparação (a última célula do notebook): referência, os modelos testados, o escolhido e o porquê. Escolher antes de olhar o teste;
- **Seção 5:** o quanto o resultado depende da divisão (a pior e a melhor parte), e a caça ao vazamento nas colunas de vocês.

No relatório

- **Seção 3:** a tabela de comparação (a última célula do notebook): referência, os modelos testados, o escolhido e o porquê. Escolher antes de olhar o teste;
- **Seção 5:** o quanto o resultado depende da divisão (a pior e a melhor parte), e a caça ao vazamento nas colunas de vocês.

Do banco de perguntas

- **9.** Existe alguma variável que só passa a ser conhecida depois que o evento acontece?
- **10.** O que vocês perderam ao trocar um modelo simples por um mais complexo?
- **11.** Se refizessem a divisão treino/teste, o resultado mudaria muito? Como vocês sabem?
- **13.** Quais modelos vocês testaram, e por que escolheram esse? Como fizeram essa escolha sem usar o teste?

Sugestão para o dataset de vocês

1. Colem a célula da tabela no notebook de vocês, depois da divisão;
2. Referência e dois ou três modelos; rodem **sem o teste**;
3. Escolham e escrevam o porquê; **só então** o teste;
4. Passem pelas colunas com a pergunta: **no momento da decisão, eu teria isso?**

Sugestão para o dataset de vocês

1. Colem a célula da tabela no notebook de vocês, depois da divisão;
2. Referência e dois ou três modelos; rodem **sem o teste**;
3. Escolham e escrevam o porquê; **só então** o teste;
4. Passem pelas colunas com a pergunta: **no momento da decisão, eu teria isso?**

Amanhã (30/09): e quando ninguém escreveu a resposta?