

Projeto da Disciplina 2 — Aprendizado de Máquina

IASEG · Prof. Mateus Levi

O que vocês vão fazer

Em grupos de 4, vocês vão construir um modelo preditivo sobre um conjunto de dados escolhido pelo grupo e documentar tanto o processo quanto o resultado.

O projeto é construído em partes: ao final de cada aula a turma leva uma tarefa que avança um pedaço. As aulas estão organizadas de forma que cada manhã ensina o que vocês precisam para a tarefa daquele dia.

O modelo pode ser de qualquer tipo — pode prever um número (quantos, quanto, quando) ou uma categoria (sim/não, qual tipo), e pode ser uma regressão, uma árvore, um k-NN ou uma floresta. A única exigência é que a pergunta que o grupo quer responder e o que o modelo devolve sejam a mesma coisa: se a pergunta é "quantos", a saída do modelo deve ser um número; se é "qual categoria", a saída deve ser uma categoria.

Prazos

Quando	O quê
22/09, monitoria	Formação dos grupos e escolha do conjunto de dados
24/09, monitoria	Último dia para trocar de conjunto de dados · aprovação de dados fora da lista · publicação do banco de perguntas · cada integrante declara por quais seções do relatório responde
02/10, 23h59	Entrega (<i>data a confirmar</i>)
05/10, manhã	Apresentação e perguntas (<i>data a confirmar</i>)

As duas últimas datas dependem de um ajuste no cronograma que ainda está sendo confirmado. Se mudarem, avisaremos com antecedência.

O que vocês entregam

Um **notebook** com todo o código necessário para treinar e aplicar o modelo — importação dos dados, treinamento, geração de previsões.

Um **relatório de no máximo 5 páginas**, com seis seções obrigatórias:

	Seção	Responde a
1	Objetivo da modelagem	que pergunta o modelo responde? que tipo de resposta ele devolve?
2	Dados utilizados	de onde vieram os dados? o que tem neles? o que vocês descartaram?
3	Desempenho e comparação	qual métrica foi usada? como o modelo se compara ao modelo de referência e a outros que vocês testaram?
4	Uso pretendido	que decisão a saída alimentaria? qual ponto de corte vocês escolheriam?
5	Limitações	onde o modelo erra?
6	Restrições de uso	para que ele não deve ser usado, mesmo funcionando bem?

O modelo do relatório, com o que vai em cada seção, será entregue no fim da primeira semana de aula.

No dia da apresentação, cada pessoa responde perguntas pelas seções que assinou — são seis seções para quatro pessoas, então a divisão não é igual, e não precisa ser. Isso é acertado dentro do grupo em 24/09.

Como escolher o conjunto de dados

O conjunto precisa ser tabular (CSV, uma linha por caso), ter entre 1.000 e 200.000 linhas e no máximo 30 colunas, ter uma coluna-alvo clara — aquilo que vocês querem prever — e ser público e já disponível para download.

Não serve: imagens, áudio, vídeo, texto livre, séries temporais, dados de mapa. Nada disso é impossível de modelar, mas exige técnicas que não são as desta disciplina.

Quatro opções já testadas (os exercícios de todas as aulas funcionam com qualquer uma delas):

	Conjunto	Tarefa	Tamanho	Observação
1	Rotatividade de clientes de telecom	classificação	7.043 × 20	26,5% cancelam · tem uma coluna com valores em branco que vocês vão ter que achar
2	Qualidade de vinhos	classificação ou regressão	6.497 × 12	só medidas químicas, não exige conhecer o domínio · dois arquivos, separador ;
3	Custo de plano de saúde	regressão	1.338 × 7	o menor e o mais direto da lista
4	Renda acima de 50 mil	classificação	48.842 × 14	vem sem cabeçalho — os nomes das colunas são passados na monitoria

```
1 https://raw.githubusercontent.com/IBM/telco-customer-churn-on-icp4d/master/data/Telco-Customer-Churn.csv
2 https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-red.csv
  https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-white.csv
3 https://raw.githubusercontent.com/stedy/Machine-Learning-with-R-datasets/master/insurance.csv
4 https://raw.githubusercontent.com/jbrownlee/Datasets/master/adult-all.csv
```

Querem usar outro? Tudo bem; tragam na monitoria de **24/09** para verificarmos se ele funciona para as tarefas. Um conjunto que parece interessante mas não permite fazer os exercícios vai atrapalhar vocês, não ajudar.

O que está sendo avaliado

★ **Um modelo que não funciona bem é um resultado perfeitamente aceitável neste projeto**, desde que vocês saibam dizer por quê e o que fariam diferente.

O que vai ser avaliado:

- A tarefa que vocês definiram corresponde ao que o modelo devolve?
- Vocês conseguem avaliar criticamente o que fizeram — por exemplo, compararam o modelo com uma referência e sabem dizer se ele é bom ou não?
- Vocês conseguem justificar as escolhas que fizeram — a métrica, o ponto de corte, as variáveis descartadas?
- Vocês sabem onde ele falha, e para que ele não deve ser usado?

O que não está sendo avaliado: quão bom o modelo é. Um grupo com um modelo ruim e a cabeça clara vale mais do que um grupo com um modelo razoável e nenhuma ideia de por quê.

A apresentação e as perguntas

Cerca de **15 minutos por grupo**: uns 5 minutos apresentando o trabalho, uns 10 minutos de perguntas.

- As perguntas são dirigidas a pessoas específicas, não ao grupo.
- **O banco de perguntas será publicado em 24/09.** Vocês vão saber de antemão o que pode ser perguntado — não para facilitar, mas para que todos estejam preparados para todas elas.
- As perguntas são sobre o projeto de vocês, não sobre teoria solta.

A tarefa depois de cada aula

Depois da	Tarefa
Aula 1 · 21/09	Olhar a lista de conjuntos de dados e pensar em qual vocês querem trabalhar

Depois da	Tarefa
Aula 2 · 22/09	Rodar as estatísticas descritivas e ajustar um primeiro modelo (<i>seções 1 e 2</i>)
Aula 3 · 23/09	Comparar com o modelo de referência; escolher e justificar uma métrica; dizer que decisão a saída alimenta (<i>seções 3 e 4</i>)
Aula 4 · 24/09	Ajustar uma árvore, produzir a curva treino × teste, dizer em que ponta da curva o modelo está
Aula 5 · 29/09	Testar outros modelos e comparar direito; procurar vazamento nos dados (<i>seções 3 e 5</i>)
Aula 6 · 30/09	— sem tarefa nova
Aula 7 · 01/10	Terminar o relatório (<i>seção 6</i>) · entrega em 02/10, 23h59