

Gabarito comentado

Projeto da disciplina - grupo: Qualidade de vinhos

Premissa adotada: tarefa de regressão. O modelo prevê a nota quality como número a partir das medições físico-químicas e do tipo do vinho. Este é um gabarito possível e coerente; classificação também seria válida se a pergunta fosse reformulada.

6.497
linhas originais

5.320
linhas após duplicatas

MAE 0,528
melhor teste

Questão 1 - Objetivo da modelagem

Que pergunta o modelo responde? O que ele devolve?

RESPOSTA-MODELO

Queremos prever a nota de qualidade atribuída ao vinho a partir de 11 medidas físico-químicas e do tipo (tinto ou branco). O modelo devolve um número, por exemplo 6,3. Portanto, a tarefa é de regressão. No uso operacional, essa nota estimada ordena amostras para uma segunda avaliação humana.

Por que regressão é uma escolha defensável?

RESPOSTA-MODELO

A variável quality é uma nota ordenada de 0 a 10 e o enunciado aceita prever um número. A escolha preserva mais informação que transformar a nota em bom/ruim. A ressalva é que regressão trata distâncias entre notas como comparáveis; isso deve ser declarado porque a nota vem de avaliação sensorial.

Questão 2 - Dados utilizados

Origem	Arquivo	Casos	Conteúdo
UCI Wine Quality	winequality-red.csv	1.599	11 medidas + quality
UCI Wine Quality	winequality-white.csv	4.898	11 medidas + quality
Base combinada	separador ','	6.497	tipo adicionado pelo grupo

- + Alvo: quality. Entradas: acidez fixa e volátil, ácido cítrico, açúcar residual, cloretos, SO2 livre e total, densidade, pH, sulfatos, álcool e tipo do vinho.
- + Não há células ausentes. As notas observadas vão de 3 a 9; a mediana é 6 e as classes são desbalanceadas.
- + Há 1.177 linhas integralmente duplicadas (240 tintos; 937 brancos). Foram removidas antes da divisão para reduzir risco de a mesma combinação aparecer em treino e teste. Restaram 5.320 casos.
- + Cuidado: sem identificador de amostra, não é possível provar que toda duplicata é erro. A exclusão é uma decisão de modelagem, não uma verdade sobre o domínio.

Questão 3 - Desempenho e comparação

Qual métrica foi usada e por quê?

RESPOSTA-MODELO


A métrica principal é o erro absoluto médio (MAE), porque sua unidade é ponto de nota: MAE 0,528 significa um erro absoluto médio de cerca de meio ponto. O RMSE é secundário e penaliza mais os erros grandes; R^2 descreve a proporção de variação explicada. Nenhuma métrica deve ser lida sem uma referência.

Como foi feita uma comparação justa?

RESPOSTA-MODELO

Após remover duplicatas, 80% dos dados (4.256 casos) foram usados para treino e validação cruzada e 20% (1.064) ficaram reservados para um único teste final. A proporção das notas foi preservada. Padronização e seleção de hiperparâmetros ocorreram dentro do pipeline, sem ajustar transformações no teste.

Modelo	MAE	RMSE	R^2	Leitura
Referência (mediana)	0,643	0,903	-0,053	piso de comparação
Regressão linear	0,566	0,729	0,313	candidato
k-NN	0,552	0,709	0,351	candidato
Árvore	0,573	0,738	0,298	candidato
Floresta aleatória	0,528	0,683	0,398	melhor



Conclusão: a floresta aleatória teve o menor MAE (0,528), uma redução de 17,8% em relação à referência que sempre prevê a mediana 6. O R^2 foi 0,398: existe sinal preditivo, mas a maior parte da variação individual ainda não é explicada.


Configurações selecionadas no treino: k-NN com $k=15$ e pesos por distância; árvore com profundidade 5; floresta com 350 árvores, todas as profundidades permitidas e 70% das variáveis consideradas a cada divisão. O número 350 foi fixado; os demais parâmetros da floresta foram comparados por validação cruzada.

Questão 3 - Diagnóstico do ajuste

Em que ponto a árvore deixa de generalizar melhor?

RESPOSTA-MODELO


A validação cruzada atinge o menor MAE perto da profundidade 5 (0,578). Depois disso, o erro de treino continua caindo, mas o erro de validação volta a subir. Essa abertura entre as curvas é evidência de sobreajuste, não de melhora real.



Em quais variáveis o melhor modelo mais se apoia?

RESPOSTA-MODELO

Pela importância de permutação no teste, álcool é o apoio mais forte: embaralhá-lo aumenta o MAE em cerca de 0,138. Em seguida aparecem acidez volátil (0,057), SO₂ livre (0,038), sulfatos (0,021) e SO₂ total (0,015). O tipo tinto/branco acrescentou quase nenhum poder preditivo depois das medições químicas.



Interpretação correta: importância de permutação mede dependência preditiva neste modelo e nesta amostra. Não prova que aumentar álcool ou alterar acidez causará uma nota maior.

Questão 4 - Uso pretendido

Que decisão a saída alimentaria?

RESPOSTA-MODELO

A saída serviria para priorizar quais lotes seguem primeiro para degustação especializada. Ela não aprova nem rejeita vinho sozinha. A decisão final permanece com o painel humano; o modelo funciona como triagem de baixo custo baseada em análises já disponíveis.

Qual ponto de corte foi escolhido?

RESPOSTA-MODELO

Definimos vinho de interesse como nota real quality ≥ 7 . No treino, usando apenas previsões fora da dobra, escolhemos o maior corte que preservava pelo menos 75% de sensibilidade: nota prevista $\geq 6,0$. No teste, esse corte selecionou 368 de 1.064 amostras, recuperou 166 dos 202 vinhos 7+ e produziu os resultados abaixo.

Métrica operacional	Resultado	Interpretação
Sensibilidade (recall)	82,2%	captura 166 de 202 vinhos 7+
Precisão	45,1%	45 em cada 100 selecionados são 7+
F1	0,582	equilíbrio entre precisão e sensibilidade
Selecionados	368 / 1064	34,6% seguem para degustação prioritária

O corte favorece não perder bons candidatos, aceitando falsos positivos. Se a degustação for cara ou a capacidade do painel for pequena, o corte deve subir. Sem custos reais, 6,0 é uma escolha didática e provisória, não uma política universal.

Questão 5 - Limitações

Onde o modelo erra?

RESPOSTA-MODELO

O erro é menor no centro da distribuição (notas 5 e 6) e muito maior nos extremos. No teste, o MAE foi 2,370 para nota 3 (n=6), 1,521 para nota 8 (n=30) e 3,343 para nota 9 (n=1). Isso é regressão para a média: há poucos exemplos extremos. O MAE também foi maior em brancos (0,554) do que em tintos (0,452).

Nota real	n no teste	MAE
3	6	2,370
4	41	1,209
5	350	0,436
6	465	0,401
7	171	0,646
8	30	1,522
9	1	3,343

Outras limitações: só há medidas químicas e nota sensorial; não há safra, produtor, preço, variedade de uva nem condições de armazenamento. A amostra é de Vinho Verde português e pode não representar outros mercados. A remoção de duplicatas também pode eliminar amostras legítimas com medições iguais.

Questão 6 - Restrições de uso

Para que o modelo não deve ser usado, mesmo funcionando bem?

RESPOSTA-MODELO

Não deve substituir degustadores ou certificação; aprovar/reprovar lotes automaticamente; estimar segurança sanitária, preço, origem ou preferência de consumidores; justificar mudanças químicas como se a importância fosse causal; nem ser aplicado a outras regiões, variedades ou laboratórios sem validação externa. Também não deve excluir definitivamente vinhos raros, justamente onde o erro é maior.

- + Uso aceitável: apoio à triagem, com degustação humana posterior e possibilidade de revisão.
- + Antes de implantar: conferir unidades e métodos de laboratório, validar em safras futuras e definir custos de falso positivo e falso negativo.
- + Depois de implantar: monitorar distribuição das entradas, MAE por faixa de nota e por tipo, volume selecionado e mudança de desempenho ao longo do tempo.

Prova oral - respostas rápidas esperadas

Pergunta da banca	Resposta curta
Qual é a unidade do MAE?	Pontos da nota de qualidade.
Por que a referência prevê 6?	É a mediana do treino e minimiza erro absoluto constante.
A floresta é boa?	É melhor que a referência, mas R^2 0,398 e extremos frágeis impedem uso autônomo.
Há vazamento?	O alvo não entra nas variáveis; duplicatas foram removidas antes do corte e o pipeline aprende só no treino.
Profundidade maior melhora a árvore?	Melhora o treino, mas piora validação após cerca de 5: sobreajuste.
Álcool causa qualidade?	Não. É associação preditiva; importância não identifica causalidade.
Por que corte 6,0 para nota real 7+?	A previsão encolhe para a média; 6,0 preservou recall mínimo de 75% no treino.
O que faria depois?	Validaria por safra/produtor, coletaria variáveis ausentes e testaria estabilidade temporal.

Critério de correção sugerido

Dimensão	Evidência mínima para resposta completa
Coerência	Pergunta, alvo e saída são todos numéricos.
Avaliação	Referência + métrica interpretável + teste preservado.
Justificativa	Duplicatas, MAE, corte e hiperparâmetros têm motivo declarado.
Crítica	Reconhece extremos raros, generalização limitada e ausência de causalidade.
Uso responsável	Decisão humana, restrições e monitoramento explícitos.

Fontes. Enunciado local: Projeto_disciplina.pdf. Dados: UCI Machine Learning Repository, Wine Quality, DOI 10.24432/C56S3T, <https://doi.org/10.24432/C56S3T>. Referência: Cortez et al. (2009), Modeling wine preferences by data mining from physicochemical properties, DOI 10.1016/j.dss.2009.05.016.

Nota ao grupo: os números deste gabarito dependem da limpeza, da divisão e da semente descritas. Se o notebook do grupo tomar decisões diferentes, o relatório deve apresentar seus próprios resultados.