

Qualidade de vinhos

Relatório do projeto de Aprendizado de Máquina

Construímos um regressor para estimar a nota sensorial de uma amostra e apoiar a ordem de degustação. A floresta aleatória reduziu o MAE de teste de 0,643 na referência para 0,529. O resultado apoia triagem humana, mas não sustenta aprovação automática, inferência causal ou transferência para outros contextos sem validação.

1 Objetivo da modelagem

A pergunta é: qual nota quality uma amostra receberia a partir de 11 medidas físico-químicas e do tipo tinto ou branco? O modelo devolve um número, como 6,3, portanto a tarefa é de regressão. A saída ordena amostras para uma segunda avaliação; a nota final continua sob responsabilidade de degustadores.

2 Dados utilizados

Usamos os arquivos públicos winequality-red.csv e winequality-white.csv do UCI Wine Quality. Cada linha representa uma amostra. Acrescentamos wine_type antes de unir os arquivos.

Etapa	Linhas	Colunas	Decisão
Arquivos originais	6.497	12 + tipo	preservar para auditoria
Após duplicatas	5.320	13	remover 1.177 repetições completas
Desenvolvimento	4.256	12 entradas	seleção e ajuste
Teste final	1.064	12 entradas	usar uma vez após as escolhas

A auditoria não encontrou ausências, textos vazios, infinitos ou perfis com entradas iguais e notas diferentes. As notas observadas vão de 3 a 9, e 76,6% dos casos têm nota 5 ou 6. Como a base não possui identificador de amostra, a remoção de duplicatas é uma escolha de modelagem, não a prova de erro no dado.

3 Desempenho e comparação

Reservamos 20% para o teste com estratificação e random_state 42. Nos 80% de desenvolvimento, todos os modelos usaram as mesmas cinco dobras de KFold embaralhado. O MAE, em pontos de nota, foi a métrica principal. RMSE e R^2 complementaram a análise.

Modelo	MAE VC	Faixa VC	MAE teste	R^2 teste
Referência (mediana)	0.643	0.626 a 0.657	0.643	-0.053
Regressão linear	0.565	0.548 a 0.585	0.566	0.313
k-NN	0.550	0.542 a 0.562	0.552	0.351
Árvore	0.582	0.566 a 0.619	0.572	0.298
Floresta aleatória	0.531	0.521 a 0.547	0.529	0.396




Figura 1 Comparação definida antes de abrir o teste final

A floresta com 350 árvores e max_features igual a 0,7 teve o menor MAE médio de validação e foi escolhida antes do teste. No teste, seu MAE foi 0.529, o RMSE 0.684 e o R^2 0.396. A redução relativa do MAE contra a referência foi 17.7%.

Na árvore, a profundidade 5 minimizou o MAE de validação. Em profundidades maiores, o erro de treino continuou caindo e o de validação subiu, padrão de sobreajuste.

4 Uso pretendido

A decisão proposta é priorizar amostras para degustação especializada. Definimos como interesse uma nota real de pelo menos 7. Com previsões fora da dobra, escolhemos o maior corte em décimos que preservou sensibilidade mínima de 75% no desenvolvimento: 6,0.

Métrica de triagem no teste	Resultado	Leitura
Sensibilidade	81.7%	165 de 202 vinhos 7+ recuperados
Precisão	44.7%	aproximadamente 45 de cada 100 selecionados são 7+
F1	0.578	equilíbrio entre precisão e sensibilidade
Volume	369 de 1064	34,7% seguem para degustação prioritária




Figura 2 Corte escolhido somente com previsões do desenvolvimento

A política favorece não perder bons candidatos. No teste, 37 vinhos com nota 7 ou maior ficaram fora da seleção e 204 amostras selecionadas não eram 7+. Se a degustação for cara ou o painel tiver pouca capacidade, o corte deve subir e ser validado em uma nova reserva; o teste atual não pode servir para recalibrar esta mesma avaliação.

5 Limitações

O modelo prevê perto do centro da distribuição e erra mais nos extremos. As notas 3 e 9 têm apenas 6 e 1 casos no teste; seus MAEs não são estimativas estáveis. O MAE foi 0,453 em tintos (n=267) e 0,554 em brancos (n=797), diferença que deve ser monitorada em novos dados.




Figura 3 Erro no teste por nota e por tipo

Variável	Aumento do MAE ao embaralhar
alcohol	0.137
volatile acidity	0.057
free sulfur dioxide	0.038
sulphates	0.021
total sulfur dioxide	0.015

Álcool, acidez volátil e dióxido de enxofre livre produziram os maiores aumentos de MAE na importância por permutação. Esse resultado descreve dependência preditiva neste modelo e nesta amostra; não prova que intervenções nessas variáveis causariam uma nota diferente.

Outras limitações incluem avaliação sensorial subjetiva, ausência de safra, produtor, variedade, preço e armazenamento, origem restrita aos vinhos estudados e possível exclusão de observações legítimas ao remover duplicatas.

6 Restrições de uso

- Não substituir degustadores, certificação ou revisão humana.
- Não aprovar ou rejeitar lotes automaticamente e não inferir segurança sanitária ou preço.
- Não interpretar importância ou coeficientes como relações causais nem orientar alterações químicas com base neles.
- Não aplicar a outras regiões, variedades, safras, períodos ou laboratórios sem validação externa e monitoramento.

Reprodução e controle de vazamento

O notebook completo usa os CSVs locais, random_state 42 e as mesmas cinco dobras para todos os modelos. Quality fica fora das entradas; as duplicatas saem antes da divisão; codificação e escala aprendem dentro do pipeline; modelo e corte são registrados antes do teste. O teste final aparece uma vez e não altera as escolhas.

Responsabilidades para a apresentação

Responsável	Seções
Integrante 1	1 Objetivo e 6 Restrições
Integrante 2	2 Dados utilizados
Integrante 3	3 Desempenho e 5 Limitações
Integrante 4	4 Uso pretendido

Referências

Cortez, P. et al. Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, 2009.

UCI Machine Learning Repository. Wine Quality. DOI 10.24432/C56S3T.

IASEG. Projeto da Disciplina 2 de Aprendizado de Máquina e Banco de perguntas, 2026.