

Qualidade de vinhos

Relatório do projeto • Regressão para apoio à degustação

6.497

amostras originais

5.320

após duplicatas

0.529

MAE no teste

17.7%

redução do MAE

1 Objetivo da modelagem


Pergunta: qual nota sensorial (quality) uma amostra receberia a partir de 11 medidas físico-químicas e do tipo tinto ou branco? O modelo devolve uma nota numérica, como 6,3. A tarefa é regressão. A saída ajuda a ordenar amostras para uma segunda degustação; a avaliação final continua humana.

2 Dados utilizados

Fonte: UCI Wine Quality, arquivos winequality-red.csv e winequality-white.csv. Cada linha representa uma amostra. Acrescentamos wine_type antes da união. A auditoria verificou ausências, valores não finitos, duplicatas completas e perfis idênticos com notas conflitantes.

Etapa	Linhas	Decisão
Arquivos originais	6.497	11 medidas, tipo e nota
Após limpeza	5.320	1.177 duplicatas completas removidas
Desenvolvimento	4.256	seleção, ajuste e corte
Teste final	1.064	avaliação depois das escolhas

Distribuição das notas originais



Auditoria

Sem ausências ou valores não finitos.

Notas observadas: 3 a 9.
76,6% são notas 5 ou 6.

Sem identificador, uma repetição pode ser legítima.

Desempenho e comparação


Escolha antes do teste: floresta aleatória com 350 árvores

3 Métrica e desenho da avaliação


Reservamos 20% com estratificação por nota e semente 42. Nos 80% de desenvolvimento, todos os modelos usaram as mesmas cinco dobras embaralhadas. MAE, em pontos de nota, foi a métrica principal; RMSE e R^2 complementam. Codificação e escala são ajustadas dentro de cada dobra.

Modelo	MAE VC	Faixa VC	MAE teste	R^2 teste
Referência (mediana)	0.643	0.626-0.657	0.643	-0.053
Regressão linear	0.565	0.548-0.585	0.566	0.313
k-NN	0.550	0.542-0.562	0.552	0.351
Árvore	0.582	0.566-0.619	0.572	0.298
Floresta aleatória	0.531	0.521-0.547	0.529	0.396

MAE médio na validação cruzada



Árvore: profundidade 5 minimiza o MAE de validação




Uso pretendido

Uma fila de degustação, não uma decisão automática

4 Decisão apoiada pela previsão

Definimos como caso de interesse uma nota real de pelo menos 7. Com previsões fora da dobra no desenvolvimento, escolhemos o maior corte em décimos que manteve sensibilidade mínima de 75%: 6,0. Amostras com previsão nesse valor ou acima seguem primeiro para degustação humana.



Métrica no teste	Resultado	Interpretação
Sensibilidade	81.7%	165 de 202 vinhos 7+ recuperados
Precisão	44.7%	aproximadamente 45 em 100 selecionados são 7+
F1	0.578	equilíbrio das duas medidas
Volume	369 de 1064	34,7% das amostras seguem primeiro


A política favorece não perder bons candidatos. No teste, 37 vinhos 7+ ficaram fora da prioridade e 204 selecionados não eram 7+. Se a capacidade do painel mudar, um novo corte precisa de validação em novos dados; o teste atual não serve para recalibrar esta avaliação.

Limitações e restrições

O que o desempenho permite afirmar

5 Onde o modelo erra

A previsão tende ao centro da distribuição e erra mais nas notas extremas. Os grupos de nota 3 e 9 têm apenas 6 e 1 casos no teste; suas médias não são estáveis. Também há diferença entre vinhos tintos e brancos, que exige acompanhamento em novos dados.



Associação preditiva não demonstra que alterar a química causará uma nota diferente.

6 Restrições de uso

Não usar para aprovar ou rejeitar lotes automaticamente, substituir degustadores, certificar segurança, estimar preço ou orientar intervenções químicas. A base não informa safra, produtor, uva, armazenamento ou identificador. Aplicações em outras regiões, variedades, períodos ou laboratórios exigem validação externa e monitoramento.

Reprodução e responsabilidades

Os CSVs locais, a semente 42 e as mesmas cinco dobras permitem repetir a análise. O alvo fica fora das entradas; duplicatas saem antes da divisão; modelo e corte são fixados antes do teste.

Seções: Daniel Gil (1 e 6); Bruno Pimentel (2); Bruno Groppo (3); Wallace Jardim (4); Reynato Junior (5).

Fontes

Cortez et al. (2009), Modeling wine preferences by data mining from physicochemical properties.
UCI Machine Learning Repository, Wine Quality, DOI 10.24432/C56S3T.
IASEG, Projeto da Disciplina 2 e Banco de Perguntas (2026).