

Qualidade de vinhos

Relatório do projeto • Estudo didático de aprendizado de máquina

Siglas: MAE = erro absoluto médio; RMSE = raiz do erro quadrático médio.

VC = validação cruzada; F1 = média harmônica da precisão e da sensibilidade.

6.497

amostras originais

5.320

após duplicatas

0.529

MAE no teste

17.7%

redução do MAE

1 Objetivo da modelagem

Queremos estimar a nota sensorial (quality) com 11 medidas químicas e o tipo do vinho. A saída é um número; por isso, usamos regressão. O estudo mostra a limpeza dos dados, o treino, a comparação dos modelos e seus limites.

2 Dados utilizados

Usamos dois CSVs públicos, um de vinhos tintos e outro de brancos. Cada linha tem 11 medidas e uma nota. Acrescentamos wine_type para indicar o tipo.

Tinto: <https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-red.csv>

Branco: <https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-white.csv>

Etapas	Linhas	Decisão
Arquivos originais	6.497	11 medidas, tipo e nota
Após limpeza	5.320	1.177 duplicatas completas removidas
Desenvolvimento	4.256	seleção, ajuste e corte
Teste final	1.064	avaliação depois das escolhas

Exemplo da base limpa: 8 linhas

Quatro tintos e quatro brancos, após retirar duplicatas. As 13 colunas aparecem em dois blocos.

linha	wine_type	quality	fixed acidity	volatile acidity	citric acid	residual sugar
0	red	5	7.40	0.70	0.00	1.90
1	red	5	7.80	0.88	0.00	2.60
2	red	5	7.80	0.76	0.04	2.30
3	red	6	11.20	0.28	0.56	1.90
1599	white	6	7.00	0.27	0.36	20.70
1600	white	6	6.30	0.30	0.34	1.60
1601	white	6	8.10	0.28	0.40	6.90
1602	white	6	7.20	0.23	0.32	8.50

linha	chlorides	free SO2	total SO2	density	pH	sulphates	alcohol
0	0.076	11	34	0.9978	3.51	0.56	9.4
1	0.098	25	67	0.9968	3.20	0.68	9.8
2	0.092	15	54	0.9970	3.26	0.65	9.8
3	0.075	17	60	0.9980	3.16	0.58	9.8
1599	0.045	45	170	1.0010	3.00	0.45	8.8
1600	0.049	14	132	0.9940	3.30	0.49	9.5
1601	0.050	30	97	0.9951	3.26	0.44	10.1
1602	0.058	47	186	0.9956	3.19	0.40	9.9

SO2 = dióxido de enxofre. Não havia valores ausentes ou não finitos.

Desempenho e comparação

Comparação pela média do erro absoluto (MAE): menor é melhor

Modelo escolhido: Floresta aleatória (350 árvores)

Por quê? Foi o menor MAE entre os modelos nas cinco dobras: 0.531.

Por que 350 árvores? O MAE caiu de 0.533 (100 árvores) para 0.531; escolhemos o menor erro.

3 Métrica e desenho da avaliação


O MAE mostra, em média, quantos pontos de nota a previsão errou. Usamos 4.256 casos para treinar e comparar nas mesmas cinco dobras. Reservamos 1.064 casos para o teste final. A proporção das notas foi mantida na divisão.

Modelo	MAE VC	Faixa VC	MAE teste
Referência (mediana)	0.643	0.626-0.657	0.643
Regressão linear	0.565	0.548-0.585	0.566
k-NN	0.550	0.542-0.562	0.552
Árvore	0.582	0.566-0.619	0.572
Floresta aleatória	0.531	0.521-0.547	0.529


Por que não os outros?

k-NN (0,550), regressão linear (0,565) e árvore (0,582) erraram mais na validação. A mediana (0,643) foi a referência mais fraca. A escolha foi feita antes de olhar o teste.

MAE médio na validação cruzada



Árvore: profundidade 5 minimiza o MAE de validação




Uso pretendido

Simulação para estudar o efeito de um ponto de corte

4 Decisão apoiada pela previsão

Usamos o corte apenas para simular uma triagem de vinhos com nota real 7+. No desenvolvimento, escolhemos 6,0: foi o maior corte que manteve pelo menos 75% de sensibilidade. Previsões de 6,0 ou mais entram na triagem.



Métrica no teste	Resultado	Interpretação
Sensibilidade	81.7%	165 de 202 vinhos 7+ recuperados
Precisão	44.7%	aproximadamente 45 em 100 selecionados são 7+
F1	0.578	equilíbrio das duas medidas
Volume	369 de 1064	34,7% recebem a classificação ilustrativa


No teste, 37 vinhos 7+ ficaram fora da triagem e 204 escolhidos não eram 7+. Por isso, a regra não pode decidir qualidade sozinha. Um novo corte exigiria validação em novos dados.

Limitações e auditoria

O que o desempenho permite afirmar

5 Onde o modelo erra

O modelo erra mais nas notas extremas. No teste, só 6 vinhos tiveram nota 3 e só 1 teve nota 9; os erros médios desses grupos são instáveis. O erro também varia entre tintos e brancos.



Associação preditiva não demonstra que alterar a química causará uma nota diferente.

Colunas e grupos no teste

wine_type quase não mudou o erro quando embaralhado. As medidas químicas já podem indicar o tipo; por isso, não concluímos que a coluna é inútil. Dióxido de enxofre livre e total têm correlação de 0.719 no desenvolvimento: também repetem parte da informação.

Tipo	Casos no teste	Nota 7+	MAE	Sensibilidade da simulação
Tinto	267	32	0.453	84.4%
Branco	797	170	0.554	81.2%

As diferenças são descritivas; a base não contém atributos pessoais protegidos.

Proxies e restrições

Aula 7 aplicada ao conjunto de vinhos

O tipo continua nas outras medidas?

Testamos se as 11 medidas químicas revelam o tipo do vinho. Depois, comparamos o MAE da floresta com e sem wine_type nas mesmas cinco dobras. Usamos só os dados de desenvolvimento para essas verificações.

Verificação	Resultado	Leitura
AUC para prever o tipo	0.996	medidas químicas quase identificam o tipo
Acurácia equilibrada	0.989	confere as duas classes apesar do desbalanceamento
MAE VC com tipo	0.531	floresta original
MAE VC sem tipo	0.531	diferença inferior a 0,001 ponto de nota

As medidas quase identificam o tipo do vinho. Retirar wine_type não apaga essa informação. O MAE mudou menos de 0,001, então não há motivo para descartar a coluna por esse teste. Esses resultados mostram associações, não causas. A base não traz dados pessoais sensíveis.

6 Restrições de uso

O modelo serve para estudo. Não deve aprovar lotes, definir preço ou indicar segurança e mudanças químicas. Faltam safra, produtor, variedade e armazenamento. Antes de usar em outro contexto, seria preciso testar novos dados e acompanhar os erros por grupo.

Resumo do projeto: o que fizemos e por quê

Pergunta	Estimamos a nota quality. Usamos regressão porque a resposta é um número.
Dados	Tiramos 1.177 duplicatas para evitar cópias em treino e teste; ficaram 5.320 linhas.
Modelo	Floresta com 350 árvores: menor MAE na validação (0.531). Com 100, foi 0.533.
Resultado	MAE 0.529 no teste, contra 0.643 da mediana: 17.7% menos erro.
Limite	O corte 6,0 só simula uma triagem. Faltam dados e o modelo erra mais nas notas extremas.