

Qualidade de vinhos

Relatório do projeto • Estudo didático de aprendizado de máquina

Siglas: MAE = erro absoluto médio; RMSE = raiz do erro quadrático médio; R^2 = coeficiente de determinação.

VC = validação cruzada; F1 = média harmônica da precisão e da sensibilidade.

6.497

amostras originais

5.320

após duplicatas

0.529

MAE no teste

17.7%

redução do MAE

1 Objetivo da modelagem

Este projeto usa a qualidade de vinhos para entender as etapas do aprendizado de máquina supervisionado: preparar dados, treinar modelos, comparar resultados em casos inéditos e examinar limitações. A pergunta é qual nota sensorial (quality) pode ser estimada a partir das 11 medidas físico-químicas e do tipo de vinho. A saída é um número; portanto, a tarefa é regressão.

2 Dados utilizados


Dois CSVs públicos (tinto e branco) trazem 11 medidas e a nota por amostra. Acrescentamos wine_type e usamos cópias locais dos links abaixo.

Tinto: <https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-red.csv>

Branco: <https://raw.githubusercontent.com/zygmuntz/wine-quality/master/winequality/winequality-white.csv>

Etapas	Linhas	Decisão
Arquivos originais	6.497	11 medidas, tipo e nota
Após limpeza	5.320	1.177 duplicatas completas removidas
Desenvolvimento	4.256	seleção, ajuste e corte
Teste final	1.064	avaliação depois das escolhas

Distribuição das notas originais



Auditoria

Nulos e não finitos: zero; nenhuma linha saiu por isso.

Duplicatas completas: 1.177; removidas antes da divisão para evitar cópias em treino e teste.

Sem identificador, algumas podem ser amostras legítimas.

Desempenho e comparação


Escolha antes do teste: floresta aleatória com 350 árvores

3 Métrica e desenho da avaliação


Reservamos 20% (1.064 casos) para avaliar previsões em dados inéditos, mantendo 80% (4.256) para treinar e escolher o modelo. Assim, o teste tem tamanho útil sem reduzir demais o desenvolvimento. A estratificação preserva a proporção das notas. Todos os candidatos usaram as mesmas cinco dobras; codificação e escala são ajustadas dentro de cada dobra.

Modelo	MAE VC	Faixa VC	MAE teste	R ² teste
Referência (mediana)	0.643	0.626-0.657	0.643	-0.053
Regressão linear	0.565	0.548-0.585	0.566	0.313
k-NN	0.550	0.542-0.562	0.552	0.351
Árvore	0.582	0.566-0.619	0.572	0.298
Floresta aleatória	0.531	0.521-0.547	0.529	0.396

MAE médio na validação cruzada



Árvore: profundidade 5 minimiza o MAE de validação




Uso pretendido

Simulação para estudar o efeito de um ponto de corte

4 Decisão apoiada pela previsão

O uso pretendido é didático: simular a identificação de amostras com nota real de pelo menos 7 e observar a troca entre sensibilidade e precisão. Com previsões fora da dobra no desenvolvimento, escolhemos o maior corte em décimos que manteve sensibilidade mínima de 75%: 6,0. Uma previsão acima do corte recebe a classificação ilustrativa de 7+.



Métrica no teste	Resultado	Interpretação
Sensibilidade	81.7%	165 de 202 vinhos 7+ recuperados
Precisão	44.7%	aproximadamente 45 em 100 selecionados são 7+
F1	0.578	equilíbrio das duas medidas
Volume	369 de 1064	34,7% recebem a classificação ilustrativa


A simulação favorece recuperar os casos 7+. No teste, 37 ficaram abaixo do corte e 204 amostras acima dele não eram 7+. Esses erros mostram que o corte não é uma decisão automática de qualidade. Qualquer novo corte precisaria ser definido e validado em novos dados.

Limitações e auditoria

O que o desempenho permite afirmar

5 Onde o modelo erra

A previsão tende ao centro da distribuição e erra mais nas notas extremas. Os grupos de nota 3 e 9 têm apenas 6 e 1 casos no teste; suas médias não são estáveis. Também há diferença entre vinhos tintos e brancos, que exige acompanhamento em novos dados.



Associação preditiva não demonstra que alterar a química causará uma nota diferente.

Colunas e grupos no teste

Wine_type teve importância isolada próxima de zero. Isso não prova que o tipo seja irrelevante: as medidas químicas podem carregar a mesma informação. Dióxido de enxofre livre e total têm correlação absoluta de 0.719 no desenvolvimento, outro exemplo de informação compartilhada. O desempenho também varia entre tintos e brancos.

Tipo	Casos no teste	Nota 7+	MAE	Sensibilidade da simulação
Tinto	267	32	0.453	84.4%
Branco	797	170	0.554	81.2%

As diferenças são descritivas; a base não contém atributos pessoais protegidos.

Proxies e restrições

Aula 7 aplicada ao conjunto de vinhos

O tipo continua nas outras medidas?

Com apenas as 11 medidas químicas do desenvolvimento, um classificador tentou prever se o vinho era tinto ou branco. Também repetimos as cinco dobras da floresta para prever `quality` após retirar `wine_type`. Nenhum desses testes consultou o conjunto reservado para escolher um novo modelo.

Verificação	Resultado	Leitura
AUC para prever o tipo	0.996	medidas químicas quase identificam o tipo
Acurácia equilibrada	0.989	confere as duas classes apesar do desbalanceamento
MAE VC com tipo	0.531	floresta original
MAE VC sem tipo	0.531	diferença inferior a 0,001 ponto de nota

O tipo é altamente recuperável pelas medidas. Tirar `wine_type`, portanto, não apaga a informação de estilo. O MAE médio quase não mudou, mas essa pequena diferença não demonstra que a coluna deva ser descartada. Importância por permutação, correlação e este teste de proxy descrevem associações do modelo, não causas. Não há variáveis pessoais sensíveis para avaliar discriminação.

6 Restrições de uso

O projeto é para compreender aprendizado de máquina. O modelo e o corte não devem decidir qualidade comercial, aprovação de lotes, preço, segurança sanitária ou mudanças químicas. A base não informa safra, produtor, variedade de uva ou armazenamento. Aplicações em outros contextos exigem validação externa e acompanhamento dos erros por grupo.

Reprodução e responsáveis

Os CSVs locais, a semente 42 e as mesmas dobras permitem reproduzir a análise. O alvo fica fora das entradas; duplicatas saem antes da divisão; preparo, modelo e corte são fixados sem consultar o teste.

Seções: Daniel Gil (1 e 6); Bruno Pimentel (2); Bruno Groppo (3); Wallace Jardim (4); Reynato Junior (5).

Fontes

Cortez et al. (2009), Modeling wine preferences by data mining from physicochemical properties.
IASEG, Projeto da Disciplina 2 e Aula 7 (2026). URLs dos CSVs na página 1.